



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Machine Learning: **Aprendizado de Máquina**

Como sistemas aprendem com dados e melhoram o desempenho sem intervenção humana direta

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo



O que vamos explorar

Dos fundamentos do aprendizado de máquina às aplicações em geotecnologias e análise de dados

- | | | | |
|----|--|----|--|
| 01 | O que é Machine Learning e como ele funciona | 05 | Principais algoritmos: Random Forest, XGBoost, SVM e KNN |
| 02 | Aprendizado supervisionado: classificação e regressão | 06 | Feature engineering e seleção de variáveis |
| 03 | Aprendizado não supervisionado: clustering e redução | 07 | Avaliação de modelos: métricas, overfitting e validação |
| 04 | Aprendizado por reforço: agentes que aprendem com o ambiente | 08 | ML aplicado a dados geoespaciais e setores estratégicos |

Sistemas que melhoram com a experiência

Machine Learning é a subárea da Inteligência Artificial que permite que sistemas aprendam com dados e melhorem o desempenho sem serem explicitamente programados para cada tarefa. Em vez de regras fixas, o modelo descobre padrões estatísticos a partir de exemplos.

Do spam filter ao recomendador da Netflix, do diagnóstico médico por imagem à previsão de desmatamento por satélite — Machine Learning está no centro da transformação digital de todos os setores.

ML EM 1 EQUAÇÃO

Dados + Algoritmo = Modelo Preditivo

- Aprende padrões sem regras explícitas
- Melhora com mais dados e experiência
- Generaliza para situações não vistas

Três paradigmas e seis algoritmos fundamentais

Supervisionado, não supervisionado e por reforço — cada paradigma com seus casos de uso



Aprendizado Supervisionado



Não Supervisionado



Por Reforço



Random Forest & Ensemble



Redes Neurais (MLP)



Gradient Boosting (XGBoost)

Aprendizado Supervisionado

O modelo aprende a partir de pares (entrada, saída esperada) rotulados por humanos. O objetivo: aprender uma função que mapeie entradas em saídas corretas para exemplos nunca vistos.

Classificação: prever categoria discreta (spam/não spam, tipo de cobertura do solo, doença presente/ausente). Regressão: prever valor contínuo (preço de imóvel, produtividade agrícola, NDVI futuro).

EXEMPLO PRÁTICO

Classificação de uso do solo: Random Forest treinado com amostras rotuladas de imagens Sentinel-2 classifica automaticamente floresta, pastagem, cultivo e área urbana com acurácia acima de 90% em escala nacional.



>90%

Acurácia de classificação supervisionada

Random Forest com features espectrais classifica cobertura do solo em escala nacional com alta precisão.



Aprendizado Não Supervisionado e Por Reforço

Não supervisionado: sem rótulos, o algoritmo descobre estruturas nos dados. K-Means e DBSCAN agrupam observações similares (clustering). PCA e UMAP reduzem dimensionalidade preservando padrões.

Aprendizado por reforço: um agente aprende por interação com o ambiente, recebendo recompensas por ações corretas. Usado em robótica, jogos (AlphaGo) e otimização de rotas logísticas.

EXEMPLO PRÁTICO

Zonas de manejo agrícola: K-Means aplicado a dados de solo (condutividade, MO, textura) e NDVI agrupa o talhão em zonas homogêneas de manejo sem nenhum rótulo prévio — base para aplicação variável de insumos.



K-MEANS GEO

Zonas de manejo definidas por clustering espacial

Agrupamento não supervisionado de atributos de solo e satélite cria zonas homogêneas no campo.

Principais algoritmos e avaliação de modelos

Random Forest, XGBoost, métricas de performance e boas práticas de validação



Random Forest e XGBoost

- Random Forest: ensemble de árvores, robusto, interpretável e versátil em dados tabulares
- XGBoost/LightGBM: gradient boosting, estado da arte para dados estruturados
- SVM: eficaz em alta dimensão — classificação de imagens hiperespectrais
- KNN: classifica por vizinhança — simples e eficaz para dados geoespaciais locais



Feature Engineering

- Transformação de variáveis: log, raiz, normalização, one-hot encoding
- Features geoespaciais: distância, densidade, lag espacial, índices espectrais
- Seleção: importance do Random Forest revela quais features mais predizem
- "Garbage in, garbage out": feature engineering vale mais que o algoritmo



Avaliação Correta

- Classificação: Acurácia, F1-Score, AUC-ROC, matriz de confusão
- Regressão: MAE, RMSE, R^2 — cada um apropriado para contextos diferentes
- Dados geo: usar validação espacial (blocos) — não aleatória — para evitar data leakage
- Overfitting: modelo memoriza treino — regularização L1/L2, dropout, early stopping

Pipeline de Machine Learning: do dado ao modelo em produção

Cinco etapas que transformam dados brutos em sistemas que aprendem e evoluem



Machine Learning: a tecnologia que aprende com o mundo

Resumo: Machine Learning transformou IA de regras codificadas manualmente em sistemas que descobrem padrões sozinhos. Do diagnóstico médico ao mapeamento de uso do solo, de detecção de fraudes ao planejamento agrícola de precisão — ML é o motor da transformação digital.

Perspectiva Futura: AutoML, modelos de fundação pré-treinados e integração de LLMs com dados estruturados estão democratizando o ML — tornando-o acessível a analistas e científicos sem formação avançada em matemática.



DADOS + ML

Sistemas que melhoram com a experiência

Do clustering de zonas de manejo à classificação de imagens —
ML no centro da DataGeo.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do dado ao modelo que aprende.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo