



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

IA Explicável (XAI) em Dados Geoespaciais

SHAP, LIME e interpretação de modelos de ML em aplicações geoespaciais e territoriais

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo

O que vamos explorar

Por que e como tornar modelos de IA geoespaciais interpretáveis e confiáveis

- | | | | |
|----|---|----|---|
| 01 | O que é XAI e por que importa em geotecnologias | 05 | Feature importance em Random Forest e XGBoost geo |
| 02 | O problema da caixa-preta: quando modelos geo erram | 06 | Mapas de explanação: visualizando XAI no território |
| 03 | SHAP: valores de Shapley para importância de features geo | 07 | XAI e regulatório: LGPD, GDPR e modelos de crédito |
| 04 | LIME: explicações locais para previsões geoespaciais | 08 | Conclusão |

Modelos que explicam o porquê da decisão territorial

IA Explicável (XAI — eXplainable AI) é o conjunto de técnicas que tornam os modelos de machine learning interpretáveis — revelando por que um modelo fez uma determinada predição. Em dados geoespaciais, isso significa entender quais features espaciais mais influenciaram cada resultado.

Um modelo de risco de crédito que usa variáveis geoespaciais deve ser explicável ao regulador. Um modelo de risco de enchente deve explicar ao gestor por que uma área específica tem alto risco. XAI fecha a lacuna entre performance e confiança.

XAI EM 1 IDEIA

Modelo + SHAP = Decisão Compreensível

- SHAP revela quais features geo mais importam
- LIME explica predições locais no território
- Reguladores exigem explicação de modelos de risco

Seis técnicas e aplicações de XAI geoespacial

De SHAP a mapas de explicação — tornando modelos geo interpretáveis



SHAP Values



LIME — Explicações Locais



Feature Importance Geo



Mapas de Explicação



Regulatório e LGPD



Confiança e Auditoria

SHAP: Quais Features Geoespaciais mais Importam

SHAP (SHapley Additive exPlanations) calcula a contribuição marginal de cada feature para uma predição específica, com base na teoria dos jogos de Shapley. Para dados geoespaciais: revela se distância ao rio, NDVI ou renda per capita da área mais contribuíram para a classificação de risco.

SHAP Summary Plot: importância global de todas as features. SHAP Force Plot: explica uma predição individual. SHAP Dependence Plot: como o valor de uma feature geoespacial afeta o output do modelo em toda a faixa de valores.

EXEMPLO PRÁTICO

Modelo de risco de enchente: SHAP revela que 'distância ao rio' (40%), 'altitude relativa' (25%) e 'cobertura do solo' (18%) são as features mais influentes — explicação que o gestor municipal entende e confia para orientar evacuação.



SHAP GEO

Feature geoespacial mais impactante revelada

SHAP transforma 'o modelo disse X' em 'distância ao rio de 200m aumentou o risco em 43%'.

LIME, Mapas de Explicação e Conformidade

Explicações locais por área, visualização territorial de XAI e obrigações regulatórias



LIME: Explicações Locais

- LIME aproxima o modelo complexo por um modelo linear simples em torno de cada ponto
- Para dados geoespaciais: explica por que um município específico foi classificado como alto risco
- Identifica quais features locais (renda, NDVI, altitude) mais pesaram naquele ponto
- Mais intuitivo que SHAP para usuários não técnicos — explica em linguagem natural



Mapas de Explicação

- SHAP values georreferenciados: mapa mostra onde cada feature tem maior impacto
- Spatial SHAP: identifica regiões onde o modelo usa mais distância vs. renda vs. NDVI
- GeoExplainer: biblioteca Python que gera mapas de explicação de modelos geoespaciais
- Visualização que reguladores, gestores e cidadãos conseguem entender e questionar



Regulatório: LGPD e GDPR

- LGPD Art. 20: direito de explicação de decisões automatizadas que afetem o titular
- Modelos de crédito com features geoespaciais devem ser explicáveis ao Banco Central
- GDPR (Europa): right to explanation — modelos automáticos precisam ser justificáveis
- XAI é requisito legal, não opcional, em modelos de crédito, saúde e segurança pública

Do modelo black-box ao sistema confiável e explicável

Quatro etapas para implementar XAI em modelos geoespaciais

01



Modelo ML Geo

Random Forest, XGBoost ou CNN treinado com features geoespaciais.



02



SHAP / LIME

Calcula importância global (SHAP) e explicação local (LIME) por predição.



03



Mapa de Explicação

SHAP values georreferenciados revelam onde cada feature domina o modelo.



04



Confiança e Auditoria

Reguladores, gestores e cidadãos entendem, confiam e podem questionar o modelo.

XAI: IA que explica, convence e conforma

Resumo: IA Explicável é a ponte entre performance e confiança: modelos geoespaciais precisos mas opacos não são aceitos por reguladores, gestores públicos ou cidadãos. SHAP, LIME e mapas de explanação tornam cada predição territorial compreensível, auditável e legalmente defensável.

Perspectiva Futura: Com a LGPD em vigor e regulamentação de IA avançando no Brasil e no mundo, XAI deixa de ser diferencial e se torna requisito. Modelos geoespaciais de crédito, saúde e segurança pública precisarão obrigatoriamente de camadas de explicabilidade.



SHAP + MAPA

Modelo geoespacial que explica sua própria decisão

De feature importance ao mapa de SHAP values — XAI que reguladores e gestores entendem.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do modelo explicável à confiança institucional.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo