

# Machine Learning Territorial com Scikit- Learn

Modelagem preditiva, validação espacial e interpretação  
de modelos territoriais

# Machine Learning Territorial com Scikit-Learn

## **DataGeo Academy** **Conhecimento que gera decisões**

Este livro mostra como aplicar Scikit-Learn em problemas territoriais: classificação de áreas prioritárias, previsão de indicadores, segmentação espacial e avaliação de modelos. A ênfase está na preparação das variáveis, prevenção de vazamento espacial, métricas compatíveis com decisão e interpretação dos resultados.

Este material foi estruturado para uso como livro técnico, apostila avançada e base para treinamentos profissionais. Os exemplos privilegiam fluxos reproduzíveis, clareza metodológica e aplicação em problemas reais de dados, território e decisão.

Atenção: códigos e bibliotecas devem ser validados no ambiente de execução antes de uso produtivo. Versões de bibliotecas, APIs e dependências podem mudar ao longo do tempo.

# Sumário

| Capítulo | Tema                                         |
|----------|----------------------------------------------|
| 1        | Formulação de problemas territoriais         |
| 2        | Base de dados e engenharia de atributos      |
| 3        | Pré-processamento e pipelines                |
| 4        | Regressão territorial                        |
| 5        | Classificação de risco e prioridade          |
| 6        | Clusterização e tipologias territoriais      |
| 7        | Árvores, Random Forest e Gradient Boosting   |
| 8        | Validação espacial e vazamento de informação |
| 9        | Interpretação e explicabilidade              |
| 10       | Implantação e scoring territorial            |
| 11       | Comunicação com mapas e painéis              |
| 12       | Projeto aplicado com Scikit-Learn            |

## Lista de figuras

Figura 1 - Do território observado ao problema modelável

Figura 2 - Construção de variáveis territoriais em múltiplas camadas

Figura 3 - Pipeline de preparação e modelagem

Figura 4 - Relação entre variáveis e valores contínuos previstos

Figura 5 - Matriz conceitual de classificação territorial

Figura 6 - Agrupamento de áreas por padrões de indicadores

Figura 7 - Estrutura conceitual de decisão em ensemble

Figura 8 - Separação espacial para validação robusta

Figura 9 - Variação da resposta do modelo a atributos-chave

Figura 10 - Fluxo de scoring territorial em produção

Figura 11 - Mapa de prioridade preditiva para decisão territorial

Figura 12 - Síntese de treinamento, teste e aplicação territorial

## Como usar este livro

O leitor deve conhecer noções básicas de Python e tabelas. A parte geográfica pode vir de GeoPandas, bancos espaciais ou planilhas com indicadores por território.

A principal mensagem deste volume é que machine learning territorial não é apenas aplicar algoritmo: é estruturar amostras, evitar vazamento espacial, validar por região e interpretar resultados dentro do contexto.

### Estrutura didática

- Ler o capítulo para compreender o conceito central.
- Reproduzir o exemplo técnico com dados próprios ou dados de treinamento.
- Aplicar o checklist de qualidade antes de transformar o resultado em produto final.
- Responder aos exercícios para fixar conceitos e identificar lacunas.

### Padrão de qualidade DataGeo Academy

A coleção segue um padrão editorial técnico: capítulos objetivos, exemplos aplicados, figuras próprias, tabelas de decisão, exercícios e projeto final. O foco não é apenas ensinar comandos, mas formar raciocínio técnico para planejar, executar, validar e comunicar análises com responsabilidade.

# Capítulo 1 - Formulação de problemas territoriais

Este capítulo aprofunda o tema Formulação de problemas territoriais dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é traduzir perguntas espaciais em problemas de previsão, classificação ou segmentação. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de alvo, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de unidade territorial, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de amostra, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de escopo, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

A unidade de análise pode ser lote, grade, bairro, setor censitário ou município. A escolha define quais variáveis fazem sentido. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

## Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a formulação de problemas territoriais e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.

- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.
- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                         |
|------------------|-------------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar formulação de problemas territoriais sem verificar compatibilidade entre dados, escala e objetivo analítico. |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.        |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros.    |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.           |




Figura 1 - Do território observado ao problema modelável. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.model_selection import GroupKFold, cross_validate

cv = GroupKFold(n_splits=5)
resultado = cross_validate(
    modelo, X, y,
    groups=municipios,
    cv=cv,
    scoring=["accuracy", "f1"]
)
```

O exemplo mostra que o alvo deve representar a decisão desejada, e não apenas uma variável disponível.

## Boas práticas para aplicação profissional

Em aplicações profissionais, traduzir perguntas espaciais em problemas de previsão, classificação ou segmentação deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que formulação de problemas territoriais é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.

- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 2 - Base de dados e engenharia de atributos

Este capítulo aprofunda o tema Base de dados e engenharia de atributos dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é construir features explicativas com coerência territorial. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de features, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de distância, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de densidade, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de contexto, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Variáveis territoriais frequentemente representam proximidade, acessibilidade, intensidade, restrição ou histórico. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a base de dados e engenharia de atributos e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.

- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.
- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                            |
|------------------|----------------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar base de dados e engenharia de atributos sem verificar compatibilidade entre dados, escala e objetivo analítico. |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.           |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros.       |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.              |




Figura 2 - Construção de variáveis territoriais em múltiplas camadas. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
# Evitar vazamento espacial
features_treino = dados[dados["ano"] <= 2022]
features_teste = dados[dados["ano"] == 2023]
# 0 teste deve representar o uso real previsto.
```

A qualidade das features costuma explicar mais o desempenho do modelo do que a escolha do algoritmo.

## Boas práticas para aplicação profissional

Em aplicações profissionais, construir features explicativas com coerência territorial deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que base de dados e engenharia de atributos é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 3 - Pré-processamento e pipelines

Este capítulo aprofunda o tema Pré-processamento e pipelines dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é padronizar transformações e reduzir erros operacionais. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de Pipeline, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de scaler, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de encoder, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de imputação, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Pipelines garantem que treino e teste recebam as mesmas transformações, evitando inconsistências e vazamento. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a pré-processamento e pipelines e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.

- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                      |
|------------------|----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar pré-processamento e pipelines sem verificar compatibilidade entre dados, escala e objetivo analítico.     |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.     |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros. |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.        |




Figura 3 - Pipeline de preparação e modelagem. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier

pipe = Pipeline([
    ("escala", StandardScaler()),
    ("modelo", RandomForestClassifier(random_state=42))
])
pipe.fit(X_treino, y_treino)
prob = pipe.predict_proba(X_teste)[: , 1]
```

O código usa a estrutura de Pipeline para manter o processo organizado.

## Boas práticas para aplicação profissional

Em aplicações profissionais, padronizar transformações e reduzir erros operacionais deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que pré-processamento e pipelines é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 4 - Regressão territorial

Este capítulo aprofunda o tema Regressão territorial dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é prever valores contínuos em unidades espaciais. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de MAE, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de RMSE, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de R2, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de resíduo, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Regressão pode estimar demanda, preço, população, risco ou intensidade de uso. O erro deve ser analisado espacialmente. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a regressão territorial e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.

- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                      |
|------------------|----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar regressão territorial sem verificar compatibilidade entre dados, escala e objetivo analítico.             |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.     |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros. |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.        |




Figura 4 - Relação entre variáveis e valores contínuos previstos. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.model_selection import GroupKFold, cross_validate

cv = GroupKFold(n_splits=5)
resultado = cross_validate(
    modelo, X, y,
    groups=municipios,
    cv=cv,
    scoring=["accuracy", "f1"]
)
```

Um modelo com bom RMSE geral pode errar sistematicamente em regiões periféricas ou áreas pequenas.

## Boas práticas para aplicação profissional

Em aplicações profissionais, prever valores contínuos em unidades espaciais deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que regressão territorial é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 5 - Classificação de risco e prioridade

Este capítulo aprofunda o tema Classificação de risco e prioridade dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é atribuir classes ou probabilidades a áreas. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de probabilidade, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de limiar, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de recall, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de falso negativo, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Classificadores podem indicar áreas de alto risco, probabilidade de ocorrência ou prioridade de intervenção. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a classificação de risco e prioridade e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.

- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                        |
|------------------|------------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar classificação de risco e prioridade sem verificar compatibilidade entre dados, escala e objetivo analítico. |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.       |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros.   |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.          |




Figura 5 - Matriz conceitual de classificação territorial. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
# Evitar vazamento espacial
features_treino = dados[dados["ano"] <= 2022]
features_teste = dados[dados["ano"] == 2023]
# 0 teste deve representar o uso real previsto.
```

A escolha do limiar é decisão de negócio: altera quantidade de áreas selecionadas e custo operacional.

## Boas práticas para aplicação profissional

Em aplicações profissionais, atribuir classes ou probabilidades a áreas deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que classificação de risco e prioridade é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 6 - Clusterização e tipologias territoriais

Este capítulo aprofunda o tema Clusterização e tipologias territoriais dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é descobrir perfis espaciais sem rótulo prévio. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de KMeans, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de perfil, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de segmentação, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de padronização, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Clusterização ajuda a criar tipologias de municípios, bairros ou setores com base em atributos socioespaciais. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a clusterização e tipologias territoriais e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.

- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                            |
|------------------|----------------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar clusterização e tipologias territoriais sem verificar compatibilidade entre dados, escala e objetivo analítico. |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.           |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros.       |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.              |




Figura 6 - Agrupamento de áreas por padrões de indicadores. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier

pipe = Pipeline([
    ("escala", StandardScaler()),
    ("modelo", RandomForestClassifier(random_state=42))
])
pipe.fit(X_treino, y_treino)
prob = pipe.predict_proba(X_teste)[0, 1]
```

A interpretação dos grupos deve ser feita com mapas e estatísticas, não apenas com centroides matemáticos.

## Boas práticas para aplicação profissional

Em aplicações profissionais, descobrir perfis espaciais sem rótulo prévio deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que clusterização e tipologias territoriais é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 7 - Árvores, Random Forest e Gradient Boosting

Este capítulo aprofunda o tema Árvores, Random Forest e Gradient Boosting dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é usar modelos robustos para padrões não lineares. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de árvore, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de ensemble, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de importância, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de interação, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Modelos baseados em árvores lidam bem com não linearidade e interações, mas podem ser mal interpretados se usados sem validação. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a árvores, random forest e gradient boosting e registrar o objetivo do produto final.

- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.
- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                       |
|------------------|-----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar árvores, random forest e gradient boosting sem verificar compatibilidade entre dados, escala e objetivo an |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de bas        |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâm        |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.         |



Figura 7 - Estrutura conceitual de decisão em ensemble. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.model_selection import GroupKFold, cross_validate
```

```
cv = GroupKFold(n_splits=5)
resultado = cross_validate(
    modelo, X, y,
    groups=municipios,
    cv=cv,
    scoring=["accuracy", "f1"]
)
```

Importância de variáveis não é causalidade; é sinal de utilidade preditiva sob aquele conjunto de dados.

## Boas práticas para aplicação profissional

Em aplicações profissionais, usar modelos robustos para padrões não lineares deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

1. Explique por que árvores, random forest e gradient boosting é relevante em um projeto territorial real.
2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.

- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 8 - Validação espacial e vazamento de informação

Este capítulo aprofunda o tema Validação espacial e vazamento de informação dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é avaliar modelos sem inflar desempenho artificialmente. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de GroupKFold, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de leakage, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de autocorrelação, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de holdout, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Em dados territoriais, amostras próximas podem ser muito semelhantes. Divisão aleatória simples pode superestimar desempenho. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a validação espacial e vazamento de informação e registrar o objetivo do produto final.

- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.
- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                       |
|------------------|-----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar validação espacial e vazamento de informação sem verificar compatibilidade entre dados, escala e objetivo. |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.      |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros.  |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.         |




Figura 8 - Separação espacial para validação robusta. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
# Evitar vazamento espacial
features_treino = dados[dados["ano"] <= 2022]
features_teste = dados[dados["ano"] == 2023]
# 0 teste deve representar o uso real previsto.
```

Validação por grupo, região ou tempo aproxima melhor o uso real do modelo.

## Boas práticas para aplicação profissional

Em aplicações profissionais, avaliar modelos sem inflar desempenho artificialmente deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que validação espacial e vazamento de informação é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 9 - Interpretação e explicabilidade

Este capítulo aprofunda o tema Interpretação e explicabilidade dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é comunicar por que o modelo prevê determinado resultado. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de importância, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de parcial dependence, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de explicação, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de confiança, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

A explicação deve ser proporcional ao risco da decisão. Modelos usados para priorização pública ou investimento exigem mais transparência. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a interpretação e explicabilidade e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.

- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                      |
|------------------|----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar interpretação e explicabilidade sem verificar compatibilidade entre dados, escala e objetivo analítico.   |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.     |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros. |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.        |




Figura 9 - Variação da resposta do modelo a atributos-chave. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier

pipe = Pipeline([
    ("escala", StandardScaler()),
    ("modelo", RandomForestClassifier(random_state=42))
])
pipe.fit(X_treino, y_treino)
prob = pipe.predict_proba(X_teste)[: , 1]
```

Interpretação deve ser acompanhada de incerteza e limitações.

## Boas práticas para aplicação profissional

Em aplicações profissionais, comunicar por que o modelo prevê determinado resultado deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que interpretação e explicabilidade é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 10 - Implantação e scoring territorial

Este capítulo aprofunda o tema Implantação e scoring territorial dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é aplicar modelos a novas áreas e atualizar resultados. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de batch, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de score, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de API, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de monitoramento, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Após treinamento, o modelo pode gerar pontuações para novas áreas. Esse processo precisa de atualização de dados, controle de versões e logs. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a implantação e scoring territorial e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.

- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                      |
|------------------|----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar implantação e scoring territorial sem verificar compatibilidade entre dados, escala e objetivo analítico. |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.     |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros. |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.        |




Figura 10 - Fluxo de scoring territorial em produção. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.model_selection import GroupKFold, cross_validate

cv = GroupKFold(n_splits=5)
resultado = cross_validate(
    modelo, X, y,
    groups=municipios,
    cv=cv,
    scoring=["accuracy", "f1"]
)
```

O scoring deve registrar data, versão dos dados e versão do modelo.

## Boas práticas para aplicação profissional

Em aplicações profissionais, aplicar modelos a novas áreas e atualizar resultados deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que implantação e scoring territorial é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 11 - Comunicação com mapas e painéis

Este capítulo aprofunda o tema Comunicação com mapas e painéis dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é apresentar resultados preditivos de forma responsável. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de mapa de probabilidade, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de ranking, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de incerteza, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de legenda, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

Mapas de probabilidade são poderosos, mas podem transmitir falsa certeza. Legendas, classes e notas metodológicas são parte do produto. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a comunicação com mapas e painéis e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reproduzível, com etapas de validação, controle de versão e rastreabilidade.

- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.
- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                      |
|------------------|----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar comunicação com mapas e painéis sem verificar compatibilidade entre dados, escala e objetivo analítico.   |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.     |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros. |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.        |




Figura 11 - Mapa de prioridade preditiva para decisão territorial. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
# Evitar vazamento espacial
features_treino = dados[dados["ano"] <= 2022]
features_teste = dados[dados["ano"] == 2023]
# 0 teste deve representar o uso real previsto.
```

A comunicação deve evitar transformar probabilidade em verdade absoluta.

## Boas práticas para aplicação profissional

Em aplicações profissionais, apresentar resultados preditivos de forma responsável deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

1. Explique por que comunicação com mapas e painéis é relevante em um projeto territorial real.
2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
5. Descreva como você documentaria o processo para permitir auditoria futura.

## Capítulo 12 - Projeto aplicado com Scikit-Learn

Este capítulo aprofunda o tema Projeto aplicado com Scikit-Learn dentro do contexto de machine learning aplicado a indicadores territoriais, áreas urbanas, logística, risco e planejamento espacial. O objetivo não é apenas apresentar conceitos, mas mostrar como eles entram em uma cadeia real de produção técnica: definição do problema, organização dos dados, seleção de métodos, validação dos resultados e comunicação das conclusões. Em projetos da DataGeo Academy, esse encadeamento é essencial porque evita que a tecnologia seja tratada como fim em si mesma. A tecnologia deve responder a uma pergunta operacional, apoiar uma decisão territorial ou melhorar a qualidade de um produto analítico.

O ponto central deste capítulo é construir um modelo territorial completo. Em termos práticos, isso significa entender quais dados são necessários, quais transformações são aceitáveis, quais pressupostos estão sendo assumidos e como documentar cada decisão. Em trabalhos com IA, machine learning e geotecnologias, uma pequena escolha técnica pode alterar significativamente o resultado final. Mudanças de projeção, agregação espacial, escala de análise, janela temporal, balanceamento de classes ou definição de alvo podem transformar um modelo aparentemente bom em uma solução frágil.

Uma leitura profissional do tema exige atenção a três dimensões: a dimensão conceitual, a dimensão computacional e a dimensão de negócio. A dimensão conceitual define o que o método representa. A dimensão computacional define como o método será implementado, testado e mantido. A dimensão de negócio esclarece quem usará o resultado, qual decisão será tomada e quais riscos surgem caso a análise esteja errada ou incompleta. Essa integração é o que diferencia uma demonstração acadêmica de uma solução aplicável em ambientes técnicos e corporativos.

No caso de dataset, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de modelo, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de validação, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

No caso de relatório, o cuidado principal é transformar o conceito em procedimento verificável. Isso envolve registrar a origem dos dados, indicar as hipóteses adotadas, manter scripts reproduzíveis e separar claramente os resultados observados das interpretações. Quando uma equipe técnica padroniza essa prática, o trabalho deixa de depender apenas da experiência individual e passa a compor um processo institucional de qualidade.

O projeto final integra todo o ciclo: problema, dados, features, modelo, validação, interpretação e mapa final. A recomendação geral é iniciar qualquer aplicação com uma pergunta bem delimitada, seguida de um inventário de dados e de um critério de sucesso. Sem esses três elementos, o projeto tende a produzir gráficos interessantes, mas pouco úteis. Com eles, a equipe consegue comparar alternativas, justificar escolhas e comunicar os resultados com mais segurança para gestores, clientes e usuários finais.

### Fluxo de trabalho recomendado

- Definir a pergunta técnica relacionada a projeto aplicado com scikit-learn e registrar o objetivo do produto final.
- Inventariar fontes de dados, metadados, restrições de uso, escala, período e qualidade disponível.
- Preparar um pipeline reprodutível, com etapas de validação, controle de versão e rastreabilidade.
- Avaliar resultados com métricas compatíveis com o problema, e não apenas com indicadores genéricos.

- Documentar decisões, limitações e possibilidades de melhoria para facilitar manutenção e auditoria.

## Decisões técnicas e critérios de qualidade

| Item             | Descrição                                                                                                      |
|------------------|----------------------------------------------------------------------------------------------------------------|
| Risco técnico    | Usar projeto aplicado com scikit-learn sem verificar compatibilidade entre dados, escala e objetivo analítico. |
| Sinal de alerta  | Resultado visualmente convincente, mas sem validação quantitativa ou sem comparação com uma linha de base.     |
| Mitigação        | Aplicar testes simples, validação cruzada quando adequada, revisão cartográfica e documentação dos parâmetros. |
| Entrega esperada | Produto técnico com método descrito, dados rastreáveis, limitações explícitas e interpretação objetiva.        |




Figura 12 - Síntese de treinamento, teste e aplicação territorial. Fonte: elaboração própria DataGeo Academy.

## Exemplo técnico aplicado

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier

pipe = Pipeline([
    ("escala", StandardScaler()),
    ("modelo", RandomForestClassifier(random_state=42))
])
pipe.fit(X_treino, y_treino)
prob = pipe.predict_proba(X_teste)[: , 1]
```

O resultado deve ser uma entrega executável e tecnicamente defensável.

## Boas práticas para aplicação profissional

Em aplicações profissionais, construir um modelo territorial completo deve ser tratado como parte de um processo, não como uma etapa isolada. A documentação deve registrar dados de entrada, parâmetros, critérios de exclusão, transformações e resultados intermediários.

Sempre que possível, compare o resultado com uma linha de base simples. Em muitos projetos, um modelo sofisticado só é justificável se superar métodos simples em qualidade, custo, estabilidade ou capacidade de explicar decisões.

A comunicação do resultado deve separar claramente mapa, métrica, interpretação e recomendação. Essa separação reduz ambiguidades e torna a entrega mais segura para equipes multidisciplinares.

## Exercícios do capítulo

- 1. Explique por que projeto aplicado com scikit-learn é relevante em um projeto territorial real.
- 2. Liste três riscos técnicos que podem comprometer a qualidade do resultado.
- 3. Defina uma métrica de avaliação compatível com o problema apresentado no capítulo.
- 4. Proponha um pequeno estudo de caso usando dados municipais, ambientais ou urbanos.
- 5. Descreva como você documentaria o processo para permitir auditoria futura.

## Projeto final orientado

Desenvolva um modelo para classificar áreas em baixa, média e alta prioridade de intervenção, usando indicadores territoriais. A unidade de análise pode ser bairro, setor censitário ou grade regular.

Inclua validação espacial por grupos, análise de importância das variáveis, mapa de resultados e relatório de limitações.

### Entregáveis recomendados

- Relatório técnico com problema, dados, metodologia, validação, resultados e limitações.
- Scripts ou notebooks organizados com execução reprodutível.
- Mapa, gráfico ou painel final com linguagem adequada ao público-alvo.
- Checklist de qualidade assinado pela equipe técnica ou responsável pelo projeto.

## Caderno prático de aplicação

Este caderno transforma os conceitos do livro em atividades orientadas. Cada laboratório foi desenhado para produzir um entregável verificável, com critérios mínimos de qualidade e documentação. A proposta é que o leitor pratique o raciocínio completo: pergunta, dados, método, validação, produto e comunicação.

Os laboratórios podem ser executados com dados reais ou simulados. Em ambiente corporativo, recomenda-se substituir os dados de exemplo por bases internas, mantendo a mesma estrutura de documentação e validação.

# Laboratório 1 - Formulação de problemas territoriais

O objetivo deste laboratório é aplicar o tema Formulação de problemas territoriais em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

## Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Laboratório 2 - Base de dados e engenharia de atributos

O objetivo deste laboratório é aplicar o tema Base de dados e engenharia de atributos em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

### Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Laboratório 3 - Pré-processamento e pipelines

O objetivo deste laboratório é aplicar o tema Pré-processamento e pipelines em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

### Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Laboratório 4 - Regressão territorial

O objetivo deste laboratório é aplicar o tema Regressão territorial em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

### Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Laboratório 5 - Classificação de risco e prioridade

O objetivo deste laboratório é aplicar o tema Classificação de risco e prioridade em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

### Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Laboratório 6 - Clusterização e tipologias territoriais

O objetivo deste laboratório é aplicar o tema Clusterização e tipologias territoriais em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

### Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Laboratório 7 - Árvores, Random Forest e Gradient Boosting

O objetivo deste laboratório é aplicar o tema Árvores, Random Forest e Gradient Boosting em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

### Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Laboratório 8 - Validação espacial e vazamento de informação

O objetivo deste laboratório é aplicar o tema Validação espacial e vazamento de informação em um fluxo técnico completo. O exercício deve começar com uma pergunta clara, seguida da identificação dos dados necessários e da definição de um produto final. Mesmo quando os dados forem simulados, o leitor deve registrar metadados, hipóteses e limitações como faria em um projeto profissional.

A primeira etapa consiste em montar uma pequena base de trabalho, verificando formato, tipos de campos, unidades, coordenadas quando existirem e consistência temporal. Em seguida, o leitor deve aplicar o método principal do laboratório, documentar parâmetros e salvar resultados intermediários. O foco não é apenas obter uma saída, mas conseguir explicar como a saída foi produzida.

Na etapa final, o resultado deve ser convertido em uma entrega compreensível: um mapa, uma tabela, um gráfico, uma função, um notebook ou uma página de relatório. A entrega deve conter interpretação objetiva e uma seção de limitações. Esse cuidado evita que resultados técnicos sejam apresentados como conclusões definitivas quando, na verdade, ainda dependem de validação e contexto.

| Etapa         | Orientação                                                                         |
|---------------|------------------------------------------------------------------------------------|
| 1. Preparação | Definir pergunta, unidade de análise, dados mínimos e critério de sucesso.         |
| 2. Execução   | Aplicar o método com parâmetros registrados e salvar resultados intermediários.    |
| 3. Validação  | Comparar com linha de base, revisar inconsistências e registrar limitações.        |
| 4. Entrega    | Produzir material final com interpretação, legenda, tabela ou código reproduzível. |

### Checklist de conclusão

- A pergunta técnica está escrita em uma frase objetiva.
- Os dados utilizados estão listados com origem, período e limitações.
- O método aplicado pode ser reproduzido por outra pessoa.
- Há pelo menos uma forma de validação ou conferência.
- O produto final comunica resultado e incerteza sem exageros.

## Glossário técnico

| Termo      | Definição                                                |
|------------|----------------------------------------------------------|
| Pipeline   | Encadeamento de etapas de pré-processamento e modelagem. |
| Feature    | Variável usada como entrada do modelo.                   |
| Leakage    | Vazamento de informação entre treino e teste.            |
| GroupKFold | Validação cruzada por grupos.                            |
| F1-score   | Métrica que combina precisão e recall.                   |
| Scoring    | Aplicação de modelo treinado a novas amostras.           |

## Referências e fontes técnicas

GeoPandas. Documentação oficial: operações espaciais, projeções, leitura e escrita de dados geográficos. Consultar a versão mais recente antes de uso produtivo.

Scikit-learn. User Guide e documentação de model selection, pipelines, métricas de classificação e regressão.

PyTorch. Documentação oficial de tensors, datasets, DataLoader, módulos neurais e treinamento de redes.

QGIS Documentation. Guias de uso para validação cartográfica, análise espacial e conferência visual de produtos geográficos.

Open Geospatial Consortium (OGC). Conceitos e padrões para interoperabilidade geoespacial, quando aplicável.

Observação editorial: esta obra é material educacional e deve ser complementada por documentação oficial, normas locais e validação técnica antes de uso em projetos críticos.