



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Deep Learning e Geotecnologias **Módulo IV:** **Aerolevantamentos**

Processamento automático de imagens, extração de feições, 3D e controle de qualidade

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo

Módulo IV: Aerolevantamentos

9 aulas com conteúdo dos PDFs originais

- | | | | |
|-------------------------|--|-------------------------|---|
| Aula
1 | Processamento Automático de Imagens Aéreas | Aula
6 | Análise de Terreno e Topografia com Deep Learning |
| Aula
2 | Classificação e Segmentação do Uso do Solo em Imagens Aéreas | Aula
7 | Planejamento e Otimização de Rotas de Voo |
| Aula
3 | Extração Automática de Feições com Deep Learning | Aula
8 | Controle de Qualidade Automatizado em Aerolevantamentos |
| Aula
4 | Estimativa de Biomassa e Características Florestais | Aula
9 | Identificação e Mapeamento de Infraestrutura Crítica |
| Aula
5 | Reconstrução 3D a partir de Dados de Aerolevantamento | | |



Processamento Automático de Imagens Aéreas

🔗 O deep learning, especialmente através de Redes Neurais Convolucionais (CNNs), tem se mostrado altamente eficaz para automatizar o processamento de grandes volumes de imagens capturadas em missões de aerolevantamento. Essas imagens, geralmente obtidas por drones, aviões ou satélites, precisam ser processadas para corrigir distorções, alinhar e criar mosaicos que representem uma visão contínua e precisa do terreno. A seguir, explico como isso funciona e apresento exemplos práticos.

APLICAÇÕES PRÁTICAS

CORREÇÃO AUTOMÁTICA DE DISTORÇÕES (ORTORRETIFICAÇÃO) • CORREÇÃO AUTOMÁTICA DE DISTORÇÕES (ORTORRETIFICAÇÃO) • CORREÇÃO AUTOMÁTICA DE DISTORÇÕES (ORTORRETIFICAÇÃO) • ALINHAMENTO DE IMAGENS E CRIAÇÃO DE MOSAICOS PRECISOS



TÓPICOS DA AULA

- Correção automática de distorções (ortorretificação)
- Correção automática de distorções (ortorretificação)
- Correção automática de distorções (ortorretificação)
- Alinhamento de imagens e criação de mosaicos precisos
- Alinhamento de imagens e criação de mosaicos precisos



Classificação e Segmentação do Uso do Solo em Imagens Aéreas

Redes Neurais Convolucionais (CNNs) são amplamente aplicadas na classificação automática de diferentes tipos de uso do solo em imagens aéreas. Através da técnica de segmentação semântica, essas redes conseguem identificar e categorizar diferentes regiões de uma imagem, associando cada pixel a uma classe específica, como áreas agrícolas, florestas, corpos d'água ou áreas urbanas. Isso facilita a criação de mapas temáticos detalhados que representam o uso da terra em uma determinada área.

APLICAÇÕES PRÁTICAS DA CLASSIFICAÇÃO AUTOMÁTICA DO

USO DO SOLO

- Agropecuária de Precisão: CNNs são usadas para monitorar grandes áreas agrícolas, classificando diferentes tipos de cultivo e detectando padrões de irrigação ou áreas que necessitam de intervenção.
- Planejamento Urbano: As redes neurais são aplicadas para identificar e monitorar o crescimento urbano, classificar diferentes zonas



TÓPICOS DA AULA

- Classificação de uso do solo em imagens aéreas
- Classificação de uso do solo em imagens aéreas
- Segmentação semântica
- Segmentação semântica
- Treinamento de cnns com dados de imagens aéreas



Extração Automática de Feições com Deep Learning

Modelos de deep learning são cada vez mais utilizados para a extração automática de feições específicas a partir de dados de aerolevantamento, como imagens de satélite e LIDAR. Esse processo envolve a identificação e segmentação de elementos como redes viárias, edifícios, rios, vegetação, e outras infraestruturas relevantes, sem a necessidade de intervenção humana manual em larga escala. Essa automação acelera significativamente o processo de mapeamento, especialmente em grandes áreas, e torna a criação de mapas e bases de dados geoespaciais mais eficiente e precisa.

APLICAÇÕES PRÁTICAS NA ATUALIZAÇÃO DE MAPAS

Gestão de Infraestrutura: Deep learning permite que empresas de energia, telecomunicações e transportes atualizem automaticamente seus mapas de infraestrutura, identificando novas redes de estradas ou estruturas como torres de transmissão e oleodutos. Planejamento Territorial: Autoridades governamentais podem usar modelos de CNN para



TÓPICOS DA AULA

- Extração automática de redes viárias
- Extração automática de redes viárias
- Identificação e mapeamento de edifícios
- Identificação e mapeamento de edifícios
- Detecção de rios e corpos d'água



Estimativa de Biomassa e Características Florestais

🔗 No contexto de aerolevantamento florestal, deep learning tem se mostrado uma ferramenta poderosa para estimar a biomassa e outras características florestais a partir de dados de imagens aéreas e LIDAR. Modelos de deep learning são capazes de processar grandes volumes de dados e inferir informações detalhadas sobre a estrutura da vegetação, incluindo altura das árvores, densidade de vegetação e volume de madeira. Seguem explicações e exemplos de como isso é realizado.

BENEFÍCIOS E APLICAÇÕES

🔗 Gestão Florestal Sustentável: Estimativas precisas de biomassa e volume de madeira ajudam na gestão sustentável das florestas e no planejamento de colheitas. 🔗 Conservação Ambiental: Monitoramento contínuo das florestas permite detectar rapidamente mudanças que podem indicar problemas ambientais.



TÓPICOS DA AULA

- Estimativa da altura das árvores
- Estimativa da altura das árvores
- Determinação da densidade de vegetação
- Determinação da densidade de vegetação
- Estimativa do volume de madeira

Reconstrução 3D a partir de Dados de Aerolevantamento

🔗 A aplicação de deep learning na criação automática de modelos 3D detalhados a partir de dados de aerolevantamento, como imagens estereoscópicas e dados LIDAR, é uma área crescente e inovadora da tecnologia geoespacial. Esses modelos 3D são essenciais para várias aplicações, incluindo planejamento urbano, arquitetura e simulação de cenários. Abaixo estão explicações detalhadas e exemplos práticos de como deep learning pode ser usado para essa finalidade.

APLICAÇÕES PRÁTICAS

CRIAÇÃO AUTOMÁTICA DE MODELOS 3D A PARTIR DE IMAGENS • CRIAÇÃO AUTOMÁTICA DE MODELOS 3D A PARTIR DE IMAGENS • GERAÇÃO DE MODELOS 3D A PARTIR DE DADOS LIDAR • GERAÇÃO DE MODELOS 3D A PARTIR DE DADOS LIDAR



TÓPICOS DA AULA

- Criação automática de modelos 3d a partir de imagens
- Criação automática de modelos 3d a partir de imagens
- Geração de modelos 3d a partir de dados lidar
- Geração de modelos 3d a partir de dados lidar
- Reconstrução de paisagens e ambiente urbano



Análise de Terreno e Topografia com Deep Learning

Modelos de deep learning têm se mostrado extremamente eficazes na análise detalhada de dados de elevação gerados por aerolevantamento, como imagens LIDAR e fotogrametria aérea. Esses modelos podem automatizar a criação de mapas de declividade, realizar análises de drenagem e identificar riscos geológicos, como áreas suscetíveis a deslizamentos de terra. Aqui estão explicações e exemplos de como deep learning é aplicado nas seguintes áreas.

APLICAÇÕES PRÁTICAS

CRIAÇÃO DE MAPAS DE DECLIVIDADE • CRIAÇÃO DE MAPAS DE DECLIVIDADE • ANÁLISE DE DRENAGEM • ANÁLISE DE DRENAGEM



TÓPICOS DA AULA

- Criação de mapas de declividade
- Criação de mapas de declividade
- Análise de drenagem
- Análise de drenagem
- Identificação de riscos geológicos



Planejamento e Otimização de Rotas de Voo

❓ O uso de deep learning no planejamento otimizado de rotas de voo em missões de aerolevantamento é uma aplicação avançada que melhora a eficiência e a eficácia das operações de coleta de dados. Modelos de deep learning podem considerar vários fatores, como a cobertura do terreno, obstáculos e a necessidade de maximizar a cobertura de dados, para criar rotas de voo que atendam aos objetivos da missão de forma mais eficaz. Aqui estão algumas explicações e exemplos de como isso pode ser aplicado.

APLICAÇÕES PRÁTICAS

ANÁLISE DA COBERTURA DO TERRENO • ANÁLISE DA COBERTURA DO TERRENO • IDENTIFICAÇÃO DE OBSTÁCULOS • IDENTIFICAÇÃO DE OBSTÁCULOS



TÓPICOS DA AULA

- Análise da cobertura do terreno
- Análise da cobertura do terreno
- Identificação de obstáculos
- Identificação de obstáculos
- Maximização da cobertura de dados

Controle de Qualidade Automatizado em Aerolevantamentos

Modelos de deep learning aplicados à verificação automática da qualidade dos dados em missões de aerolevantamento têm se mostrado bastante eficazes, especialmente em projetos de grande escala, como levantamentos geoespaciais. Aqui estão alguns exemplos e explicações sobre como esses modelos podem ser utilizados:

APLICAÇÕES PRÁTICAS

DETECÇÃO DE ARTEFATOS EM IMAGENS • DETECÇÃO DE ARTEFATOS EM IMAGENS • VERIFICAÇÃO DA RESOLUÇÃO • VERIFICAÇÃO DA RESOLUÇÃO



TÓPICOS DA AULA

- Detecção de artefatos em imagens
- Detecção de artefatos em imagens
- Verificação da resolução
- Verificação da resolução
- Identificação de áreas para recolha de dados

Identificação e Mapeamento de Infraestrutura Crítica

🔗 O uso de deep learning para a identificação e mapeamento de infraestrutura crítica, como linhas de transmissão elétrica, oleodutos e gasodutos, a partir de dados de aerolevantamento, é uma aplicação poderosa que melhora a eficiência e a precisão no gerenciamento dessas infraestruturas. Isso é especialmente importante para a manutenção e planejamento em áreas de difícil acesso. Aqui estão explicações e exemplos de como deep learning é aplicado nesse contexto.

APLICAÇÕES PRÁTICAS

IDENTIFICAÇÃO DE LINHAS DE TRANSMISSÃO ELÉTRICA • IDENTIFICAÇÃO DE LINHAS DE TRANSMISSÃO ELÉTRICA • MAPEAMENTO DE OLEODUTOS • MAPEAMENTO DE OLEODUTOS



TÓPICOS DA AULA

- Identificação de linhas de transmissão elétrica
- Identificação de linhas de transmissão elétrica
- Mapeamento de oleodutos
- Mapeamento de oleodutos
- Identificação de gasodutos



DataGeo
Academy

Obrigado!

Processamento automático de imagens, extração de feições, 3D e controle de quali

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo