



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Deep Learning e Geotecnologias **Módulo VI:** **Conhecimentos Específicos**

Backpropagation, Vision Transformers, Mask R-CNN, Modelos Híbridos e Funções ReLU

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo

Módulo VI: Conhecimentos Específicos

5 aulas extras com conteúdo dos PDFs originais

Extra
1 | Backpropagation — O Algoritmo de Treinamento das Redes Neurais

Extra
2 | Vision Transformers (ViT) — Atenção em Visão Computacional

Extra
3 | Mask R-CNN — Detecção e Segmentação de Instâncias

Extra
4 | Modelos Híbridos de Deep Learning

Extra
5 | Funções ReLU — Não-Linearidade nas Redes Neurais



Backpropagation — O Algoritmo de Treinamento das Redes Neurais

❓ Backpropagation (propagação para trás) é um algoritmo utilizado para treinar redes neurais artificiais. Ele ajusta os pesos das conexões entre os neurônios para minimizar o erro entre as previsões do modelo e os resultados reais, tornando o modelo mais preciso ao longo do tempo. O backpropagation é a base do aprendizado em redes neurais profundas e funciona de forma iterativa.

TÓPICOS-CHAVE



- Como funciona o backpropagation
- Forward pass (passagem direta)
- Cálculo do erro
- Backward pass (propagação para trás)

COMO FUNCIONA O BACKPROPAGATION

Forward Pass (Passagem Direta) Cálculo do Erro Backward Pass (Propagação para Trás) Atualização dos Pesos Exemplo

FORWARD PASS (PASSAGEM DIRETA)

❓ Forward Pass (Passagem direta): Os dados de entrada são enviados para a rede neural, passando camada por camada até chegar à camada de saída. A rede faz uma previsão com base nesses dados, gerando u

CÁLCULO DO ERRO

❓ Cálculo do erro: A diferença entre a saída prevista e a saída real (ou esperada) é calculada. Essa diferença é chamada de erro ou custo. O objetivo do treinamento é minimizar esse erro.

Vision Transformers (ViT) — Atenção em Visão Computacional

📖 Vision Transformers (ViTs) são uma classe de modelos de deep learning baseados na arquitetura Transformer, originalmente desenvolvida para processamento de linguagem natural (NLP), que agora está sendo aplicada a tarefas de visão computacional, como classificação de imagens e segmentação.

TÓPICOS-CHAVE



- Principais características dos vision
- Divisão de patches
- Positional encoding
- Mecanismo de atenção

PRINCIPAIS CARACTERÍSTICAS DOS VISION

TRANSFORMERS (ViTs) Divisão de Patches Positional Encoding
Mecanismo de Atenção Treinamento com Grande Quantidade
de Dados Exemplo de Aplicação Diferença com CNNs

DIVISÃO DE PATCHES

📖 Em vez de processar diretamente uma imagem como um todo, o ViT divide a imagem em pequenos patches (blocos de pixels). Esses patches são tratados como uma sequência de "tokens", similar ao que aconte

POSITIONAL ENCODING

📖 Como os Transformers não têm noção de ordem espacial por padrão (ao contrário das CNNs), o ViT usa embeddings posicionais para incorporar informações sobre a localização dos patches dentro da imagem

Mask R-CNN — Detecção e Segmentação de Instâncias

❓ A Mask R-CNN (Mask Region-based Convolutional Neural Network) é uma extensão da arquitetura Faster R-CNN, projetada para realizar não apenas a detecção de objetos, mas também a segmentação semântica (ou segmentação de instâncias). Ela é amplamente utilizada em visão computacional para identificar, classificar e gerar máscaras precisas para cada objeto em uma imagem, o que a torna uma ferramenta poderosa para tarefas como segmentação de imagens e visão autônoma.

TÓPICOS-CHAVE



- Componentes principais da mask r-cnn
- Backbone (extrator de features)
- Regions personal network (rpn)
- Classificação e regressão de bounding box

COMPONENTES PRINCIPAIS DA MASK R-CNN

Backbone (Extrator de Features) Regions Personal Network (RPN) Classificação e Regressão de Bounding Box Branch de Segmentação (Mask Branch)

BACKBONE (EXTRATOR DE FEATURES)

❓ A rede começa com uma arquitetura de rede convolucional (geralmente uma CNN como ResNet ou ResNeXt) para extração de features das imagens de entrada. Essas features servem de base para identificar o

REGIONS PERSONAL NETWORK (RPN)

❓ Similar à Faster R-CNN, a Mask R-CNN utiliza uma Rede de Propostas de Regiões (RPN) que gera propostas de regiões que têm alta probabilidade de conter objetos. Essas propostas são áreas candidatas a



Modelos Híbridos de Deep Learning

TÓPICOS-CHAVE





Funções ReLU — Não-Linearidade nas Redes Neurais

📖 Como funções ReLU (redes neurais e aprendizagem profunda). Elas desempenham um papel fundamental na modelagem de relações não lineares, essencial para o aprendizado de padrões complexos em grandes volumes de dados. Aqui está uma explicação mais detalhada sobre o que é, sua utilidade e importância:

TÓPICOS-CHAVE

- 
- Funções relu
 - Utilidade das funções relu
 - Importância das funções relu
 - Desvantagens e variações das funções relu

FUNÇÕES RELU

O que são Utilidade das Funções ReLU Importância das Funções ReLU Desvantagens e Variações das Funções ReLU Exemplos de Aplicações

UTILIDADE DAS FUNÇÕES RELU

A função ReLU é útil por várias razões no contexto de redes neurais: Introdução de não-linearidade : Redes neurais, para resolver problemas complexos, precisam ser capazes de modelar relações não line

IMPORTÂNCIA DAS FUNÇÕES RELU

Treinamento de redes profundas : ReLU foi um avanço importante na área de aprendizagem profunda porque permitiu que redes neurais muito profundas fossem treinadas de maneira eficiente. Antes da ReLU,



DataGeo
Academy

Obrigado!

Backpropagation, Vision Transformers, Mask R-CNN, Modelos Híbridos e Funções ReL

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo