



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Fundamentos de **Machine Learning**

Conceitos, tipos de aprendizado, algoritmos e o pipeline completo de um modelo ML

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo



O que vamos explorar

Do conceito básico ao pipeline completo de Machine Learning

- | | | | |
|----|---|----|--|
| 01 | O que é Machine Learning e por que importa | 05 | Pré-processamento e engenharia de features |
| 02 | Aprendizado supervisionado: classificação e regressão | 06 | Treinamento, validação e avaliação de modelos |
| 03 | Aprendizado não supervisionado e por reforço | 07 | Overfitting, regularização e generalização |
| 04 | Principais algoritmos e quando usar cada um | 08 | Pipeline completo: do dado bruto ao modelo em produção |

Quando a máquina aprende com os dados

Machine Learning (ML) é uma subárea da IA que permite que sistemas aprendam e melhorem a partir da experiência sem serem explicitamente programados para cada tarefa.

Em vez de regras fixas, o modelo aprende padrões diretamente dos dados — classificar imagens, prever preços, detectar fraudes ou recomendar conteúdo.

O resultado é um sistema que generaliza o conhecimento para dados nunca vistos, tomando decisões com base estatística e matemática robusta.

ML EM 1 EQUAÇÃO

Dados + Algoritmo = Modelo

- Aprende padrões sem programação explícita
- Generaliza para dados novos
- Melhora com mais experiência

Três paradigmas + seis algoritmos fundamentais

Supervisionado, não supervisionado, por reforço — cada um com casos de uso distintos



Aprendizado Supervisionado



Não Supervisionado



Por Reforço



Árvores de Decisão & Ensemble



Métodos Lineares



Redes Neurais



Aprendizado Supervisionado

O modelo aprende a partir de pares (entrada, saída) rotulados. Objetivos: Classificação (prever categoria, ex.: spam/não spam) e Regressão (prever valor contínuo, ex.: preço de imóvel).

Algoritmos principais: Regressão Linear/Logística, Árvores de Decisão, Random Forest, SVM, KNN e Gradient Boosting (XGBoost/LightGBM).

EXEMPLO PRÁTICO

Regra prática: XGBoost com bons dados é o padrão para dados tabulares. Dados com relações não lineares complexas pedem redes neurais. Dados poucos pedem Naive Bayes ou SVM.



AUC>0.85

Benchmark de qualidade para classificação

AUC-ROC mede a capacidade do modelo de distinguir classes — acima de 0.85 é referência de mercado.



Pré-processamento e Engenharia de Features

A qualidade do modelo depende diretamente da qualidade dos dados. Pré-processamento envolve limpeza de dados faltantes, normalização, codificação de categóricas e tratamento de outliers.

A engenharia de features cria novas variáveis a partir das existentes, ampliando o poder preditivo. É frequentemente mais impactante do que a escolha do algoritmo.

EXEMPLO PRÁTICO

"Garbage in, garbage out": modelos sofisticados aplicados a dados sujos geram previsões ruins. Cientistas de dados gastam até 80% do tempo nesta etapa antes de treinar qualquer modelo.



80%

do tempo em dados, 20% no modelo

Limpeza, normalização e feature engineering têm mais impacto que a escolha do algoritmo.

Treinamento, avaliação e generalização

Um modelo precisa performar bem em dados nunca vistos — não apenas no treino



Divisão Train/Val/Test

- Train set: ajusta os parâmetros do modelo
- Validation set: ajuste de hiperparâmetros
- Test set: avaliação final — nunca use antes!
- Cross-validation (k-fold): avaliação robusta com todos os dados



Métricas de Avaliação

- Classificação: Acurácia, F1-Score, AUC-ROC
- Regressão: MAE, RMSE, R^2
- Matriz de confusão: visualiza erros por classe
- A métrica certa depende do custo de cada erro



Overfitting e Regularização

- Overfitting: memoriza o treino, falha em novos dados
- Underfitting: modelo simples demais
- Regularização L1 (Lasso) e L2 (Ridge)
- Dropout e early stopping para redes neurais

Pipeline: do dado bruto ao modelo em produção

Cinco etapas que transformam dados brutos em valor mensurável



ML é uma ferramenta, não magia

Resumo: Machine Learning fornece um conjunto poderoso de técnicas para extrair padrões de dados. O sucesso depende de dados de qualidade, escolha criteriosa do algoritmo, avaliação honesta e entendimento do domínio.

Perspectiva Futura: Com a crescente disponibilidade de dados e poder computacional, os limites do ML seguem se expandindo. A próxima fronteira está em modelos mais eficientes, interpretáveis e capazes de aprender com poucos exemplos (few-shot learning).



DADOS + DOMÍNIO

A combinação vencedora

Bons dados e entendimento do problema valem mais do que o algoritmo mais avançado.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do dado bruto ao modelo inteligente.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo