



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Redes Neurais e Deep Learning

Arquiteturas, funcionamento e aplicações em visão, linguagem e dados geoespaciais

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo



O que vamos explorar

Do neurônio artificial às arquiteturas que dominam a IA moderna

- | | | | |
|----|--|----|------------------------------------|
| 01 | O neurônio artificial e backpropagation | 05 | Autoencoders e U-Net — segmentação |
| 02 | Redes Convolucionais (CNN) — visão computacional | 06 | GANs e aprendizado generativo |
| 03 | Redes Recorrentes (RNN, LSTM) — séries temporais | 07 | Transfer Learning e Fine-tuning |
| 04 | Transformers e mecanismo de Atenção | 08 | Conclusão e modelos de fundação |

Quando as máquinas aprendem a ver, ouvir e ler

Deep Learning é um subconjunto de ML baseado em redes neurais com múltiplas camadas de transformação. Cada camada aprende representações progressivamente mais abstratas dos dados.

O que tornou DL o estado da arte foi a combinação de grandes volumes de dados, GPUs de alta performance e avanços em arquiteturas (ResNet, Transformer) e funções de ativação (ReLU).

DEEP LEARNING EM 1 IDEIA

Camadas + Dados = Representação

- Aprende hierarquia automática de features
- Escala com mais dados e poder computacional
- Estado da arte em visão, linguagem e áudio



Seis arquiteturas fundamentais

Cada arquitetura foi criada para capturar uma estrutura diferente dos dados



Redes Densas (MLP/DNN)



Convolucionais (CNN)



Recorrentes (RNN/LSTM)



Transformers & Attention



Autoencoders / U-Net



GANs Generativas

Redes Convolucionais (CNN) — Visão Computacional

CNNs aplicam filtros convolucionais sobre a entrada, detectando padrões locais como bordas, texturas e formas. Camadas de pooling reduzem a dimensão preservando informações relevantes.

Arquiteturas icônicas: VGG, ResNet (conexões residuais), EfficientNet. Em dados geoespaciais, CNNs classificam imagens de satélite com precisão acima de 95%.

EXEMPLO PRÁTICO

YOLO para detecção de objetos: arquitetura CNN em tempo real usada em imagens de satélite para mapeamento automático de edifícios, estradas e veículos, processando frames a dezenas de FPS.



>95%

Precisão na classificação de imagens de satélite

ResNet e EfficientNet com transfer learning superam classificação manual em escala e velocidade.



Redes Recorrentes (LSTM, GRU) — Séries Temporais

LSTMs processam sequências mantendo memória de longo prazo com portas de controle (input, forget, output). Resolvem o vanishing gradient das RNNs simples.

São o padrão para séries temporais de sensores, previsão climática, monitoramento de infraestrutura e séries multiespectrais de satélite.

EXEMPLO PRÁTICO

Predição de NDVI com LSTM: modelos treinados em séries temporais de imagens Sentinel-2 preveem o índice de vegetação futuro de uma lavoura com semanas de antecedência, apoiando planejamento agrícola.



LSTM+GRU

Memória de longo prazo em séries de sensores

GRU é mais leve que LSTM com performance similar — escolha pelo trade-off velocidade vs. precisão.

Transformers e Mecanismo de Atenção

Transformers processam toda a sequência em paralelo via Self-Attention, que pondera a relevância de cada token em relação a todos os outros — eliminando a necessidade de processamento sequencial.

BERT, GPT e ViT (Vision Transformer) são referências. Spatial Transformers e Geo-Foundation Models estendem a arquitetura para dados geoespaciais.

EXEMPLO PRÁTICO

Prithvi (IBM + NASA): modelo de fundação geoespacial baseado em Transformers, pré-treinado em 6 anos de imagens HLS. Fine-tuning rápido para classificação, inundações e incêndios.



ViT+GEO

Vision Transformers em imagens de satélite

Pré-treino em bilhões de pixels permite fine-tuning com poucos exemplos rotulados.

Autoencoders, GANs e Transfer Learning

Geração, compressão e transferência de conhecimento entre tarefas




Autoencoders / U-Net

- Encoder comprime dados em espaço latente (bottleneck)
- U-Net: skip connections para segmentação precisa de imagens
- Amplamente usado em imagens médicas e de satélite
- Detecção de anomalias: alta perda de reconstrução = outlier



GANs (Generativas)

- Gerador vs. Discriminador em jogo adversarial
- Super-resolução de imagens de satélite (SRGAN)
- Data augmentation com amostras sintéticas de classes raras
- CycleGAN: transformação de domínio sem pares rotulados



Transfer Learning

- Reaproveita pesos de modelos pré-treinados em grandes datasets
- Feature extraction: congela camadas, treina só a cabeça
- Fine-tuning: ajusta todas as camadas com LR baixo
- Reduz custo de treino de semanas para horas

Como escolher a arquitetura certa para o seu problema

A estrutura dos dados determina qual tipo de rede usar

01



Imagens / Grade

CNN ou Vision Transformer. U-Net para segmentação pixel a pixel.

02



Sequências

LSTM/GRU para séries temporais;
Transformer para NLP.

03



Dados Tabulares

MLP ou gradient boosting (XGBoost) ainda superam DL.

04



Dados Escassos

Transfer Learning + fine-tuning ou GANs para dados sintéticos.

Deep Learning: poder e responsabilidade

Resumo: Redes neurais profundas atingiram níveis super-humanos em visão, linguagem e jogos. No domínio geoespacial, abriram a porta para mapeamento global automático e previsão territorial de alta precisão.

Perspectiva Futura: Modelos multimodais (texto + imagem + coordenadas) e de fundação geoespaciais serão a próxima onda, democratizando análises que hoje exigem grandes equipes especializadas.



FOUNDATION MODEL

Pré-treino massivo, fine-tuning rápido

Prithvi (NASA/IBM) e SATLAS democratizam Deep Learning geoespacial com dados escassos.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — da camada de entrada ao mapa preditivo.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo