



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Machine Learning no Mercado Financeiro

Previsão, detecção de fraudes, credit scoring e trading algorítmico com ML

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo



O que vamos explorar

Como algoritmos de ML remodelam finanças quantitativas e decisões de crédito

- | | | | |
|----|--|----|--|
| 01 | Por que ML e finanças são complementares | 05 | Trading algorítmico e sistemas quantitativos |
| 02 | Credit scoring e avaliação de risco de crédito | 06 | Gestão de risco regulatório (Basel / IFRS 9) |
| 03 | Detecção de fraudes e lavagem de dinheiro | 07 | NLP financeiro e sentiment analysis |
| 04 | Previsão de séries temporais financeiras | 08 | Conclusão: IA explicável e desafios éticos |

Quando algoritmos movem mercados

O mercado financeiro é um dos domínios mais ricos em dados e com maior incentivo para extrair padrões preditivos — preços, volumes, notícias, relatórios e geolocalização alimentam modelos sofisticados.

ML já é padrão em bancos para credit scoring, seguradoras para precificação de risco, fundos para trading e reguladores para vigilância de mercado.

ML + FINANÇAS EM 1 IDEIA

$$\text{Sinal} + \text{Risco} = \text{Alpha}$$

- Mais precisão em credit scoring
- Detecção de fraudes em tempo real
- Alpha em estratégias quantitativas

Seis aplicações centrais

De crédito a compliance, ML remodela cada função do setor financeiro



Credit Scoring



Detecção de Fraudes



Previsão de Séries



Trading Algorítmico



Gestão de Risco



NLP Financeiro



Credit Scoring e Avaliação de Risco de Crédito

Modelos de ML superam escores tradicionais (FICO) ao incorporar centenas de variáveis: comportamento de pagamento, dados geoespaciais da região, histórico de conta corrente e dados alternativos.

XGBoost e LightGBM são os algoritmos mais usados, com AUC-ROC tipicamente acima de 0.85 em datasets financeiros de qualidade.

EXEMPLO PRÁTICO

Nubank e fintechs: aprovam crédito para populações sem histórico bancário usando dados alternativos e comportamentais, expandindo inclusão financeira com inadimplência controlada.



>0.85

AUC-ROC em modelos modernos de crédito

XGBoost com features comportamentais e geoespaciais supera escores tradicionais em discriminação.

Detecção de Fraudes e Lavagem de Dinheiro

Fraude é um problema extremamente desbalanceado: menos de 0.1% das transações são fraudulentas. Técnicas de oversampling (SMOTE) e modelos de anomalia são essenciais.

Graph Neural Networks (GNN) são o estado da arte em lavagem de dinheiro, modelando redes de transações e detectando padrões circulares e estruturas de "smurfing".

EXEMPLO PRÁTICO

Visa e Mastercard: processam bilhões de transações com modelos ML que decidem em menos de 100ms, reduzindo fraudes em bilhões por ano com mínimo de falsos positivos.



<100ms

Decisão de fraude por transação

Modelos leves em produção decidem em milissegundos; GNNs analisam redes de lavagem em batch.



Trading Algorítmico e Sistemas Quantitativos

Trading algorítmico usa ML para gerar sinais de compra/venda, otimizar execução e alocar capital. Aprendizado por reforço cria agentes que aprendem estratégias diretamente no ambiente de mercado.

Pipeline: features (técnicas + alternativas) → sinal ML → backtesting rigoroso → paper trading → produção. Overfitting ao backtesting é o principal risco.

EXEMPLO PRÁTICO

Walk-forward validation: testar centenas de estratégias até encontrar uma lucrativa no backtesting é uma armadilha. Validação out-of-sample rigorosa e custos de transação realistas são obrigatórios.



Sharpe>1

Benchmark mínimo de qualidade da estratégia

Backtesting robusto com walk-forward e custos realistas é obrigatório antes de qualquer deploy.

Risco regulatório, NLP e FinTech

ML aplicado a compliance, sentiment analysis e open finance



Gestão de Risco (Basel/IFRS 9)

- IFRS 9 exige PD prospectiva baseada em ML
- Stress testing: simula cenários macroeconômicos adversos
- VaR e Expected Shortfall com modelos de regime
- Explainability (SHAP) obrigatória para reguladores



NLP Financeiro

- Sentiment analysis de notícias, redes sociais e relatórios
- Análise de atas do Banco Central com BERT
- Extração de informações de balanços (LLMs)
- Alertas regulatórios automáticos por monitoramento de legislação



FinTech e Open Finance

- Open Finance: ML sobre dados de múltiplas instituições
- Recomendação personalizada de investimentos
- Precificação dinâmica de seguros com IoT e dados geoespaciais
- Chatbots financeiros com LLMs fine-tuned em domínio bancário

Pipeline de ML financeiro: do sinal à ordem

Quatro etapas críticas com pontos de falha que precisam ser controlados

01



Dados Alternativos

Satélite, NLP, transacionais, geoespaciais e dados de mercado.



02



Feature Engineering

Fatores técnicos e alternativos com controle de look-ahead bias.



03



Modelo ML

Walk-forward, controle de overfitting e validação out-of-sample.



04



Execução

Sizing, gerenciamento de risco e custos de transação realistas.

ML financeiro: poder com responsabilidade

Resumo: ML já é infraestrutura no setor financeiro: de credit scoring a detecção de fraudes em tempo real. A vantagem competitiva vem da combinação de dados de qualidade, feature engineering especializado e validação rigorosa.

Perspectiva Futura: LLMs especializados em finanças (BloombergGPT, FinBERT), IA explicável para reguladores e sistemas de risco em tempo real com dados geoespaciais serão as próximas fronteiras.



EXPLAINABLE AI

Reguladores exigem transparência nos modelos

SHAP values e LIME são obrigatórios para modelos de crédito e gestão de risco regulados.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do sinal quântico à ordem de mercado.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo