



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

MLOps e **Deploy** de Modelos

Ciclo de vida, versionamento, monitoramento e produção de modelos de ML em escala

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo



O que vamos explorar

Do notebook ao sistema produtivo: engenharia de ML em escala

- | | | | |
|----|--|----|--|
| 01 | O que é MLOps e por que apenas 22% dos modelos chegam à produção | 05 | Model Serving: REST API, gRPC e Batch Inference |
| 02 | Experiment Tracking e Model Registry (MLflow, W&B) | 06 | Monitoramento: data drift, concept drift e model decay |
| 03 | Versionamento de dados com DVC | 07 | Feature Store e Governança de modelos |
| 04 | CI/CD para ML: pipelines e testes automatizados | 08 | Níveis de maturidade MLOps e conclusão |

Do notebook ao sistema que gera valor real

MLOps (Machine Learning Operations) é o conjunto de práticas, ferramentas e cultura que permitem treinar, implantar, monitorar e manter modelos de ML em produção de forma confiável e eficiente.

Estudos apontam que apenas 22% dos modelos ML chegam a produção. MLOps existe para mudar essa estatística, trazendo rigor de engenharia de software para o mundo do ML.

MLOPS EM 1 IDEIA

$$\text{DevOps} + \text{DataOps} = \text{MLOps}$$

- Reproducibilidade total dos experimentos
- Deploy confiável e rápido de novos modelos
- Monitoramento contínuo e retreino automático

Sete pilares do MLOps

Cada pilar elimina um ponto crítico de falha entre o desenvolvimento e a produção



Experiment Tracking



Versionamento de
Dados



CI/CD para ML



Model Serving



Monitoramento



Governança



Feature Store



Experiment Tracking e Model Registry

Sem rastreamento, é impossível reproduzir resultados. MLflow, Weights & Biases e Neptune.ai registram automaticamente hiperparâmetros, métricas, artefatos e o ambiente de execução de cada experimento.

O Model Registry armazena versões com metadados, permite comparar experimentos, promover modelos (Staging → Production) e reverter rapidamente em caso de problemas.

EXEMPLO PRÁTICO

MLflow + DagsHub: combinação open source que registra experimentos com 3 linhas de código (`mlflow.autolog()`), versiona código com Git e dados com DVC, criando link único entre dado, código e modelo.



MLFLOW

Rastreamento e Model Registry open source

*Um experimento sem tracking é um experimento perdido.
MLflow loga hiperparâmetros automaticamente.*



CI/CD para ML: Pipelines Automatizados

CI/CD para ML automatiza o ciclo treino → avaliação → deploy sempre que há novo dado ou código. Ferramentas como GitHub Actions, Kubeflow Pipelines e ZenML orquestram cada etapa.

Continuous Training (CT) re-treina automaticamente com novos dados. Testes automáticos validam qualidade dos dados (Great Expectations) e performance antes de qualquer promoção.

EXEMPLO PRÁTICO

Pipeline no GitHub Actions: push de código aciona: lint → validação de dados → treino → avaliação automática → push ao registro → deploy em staging → testes de fumaça → produção.



CT+CD

Treino e deploy contínuos automatizados

Novos dados disparam retreino automático; modelos que superam baseline são promovidos sem intervenção.



Model Serving: disponibilizando modelos em produção

Servir um modelo significa torná-lo acessível para aplicações. Principais abordagens: REST API (FastAPI, Flask), gRPC para baixa latência, e Batch Inference para grandes volumes.

BentoML, Seldon, TorchServe e Vertex AI Prediction abstraem a infraestrutura, gerenciam auto-scaling e oferecem logs, métricas e rolling deployments.

EXEMPLO PRÁTICO

Padrões de deploy: Blue/Green (zero downtime), Canary Release (roll-out gradual com 5% do tráfego) e A/B Testing (comparação de dois modelos em produção com métricas de negócio).



CANARY

Deploy gradual com controle de risco

Canary expõe o novo modelo a 5-10% do tráfego, revertendo se métricas piorarem.

Monitoramento, Feature Store e Governança

O modelo em produção precisa ser vigiado continuamente



Monitoramento em Produção

- Data drift: distribuição dos dados de entrada muda
- Concept drift: relação entre features e target se altera
- Model decay: performance cai por mudanças no ambiente
- Ferramentas: Evidently AI, WhyLabs, Arize, Prometheus



Feature Store

- Repositório centralizado de features para treino e serve
- Elimina training-serving skew: mesma feature em ambos
- Reutilização de features entre times e projetos
- Feast, Tecton, Hopsworks e Vertex AI Feature Store




Governança e IA Responsável

- Explainability: SHAP, LIME e Integrated Gradients
- Fairness: métricas de equidade entre grupos demográficos
- Privacidade: Federated Learning e Differential Privacy
- Auditabilidade: lineage de dados e modelos rastreável

Níveis de maturidade em MLOps (Google ML Engineering)

Cada nível multiplica a velocidade de entrega e a confiabilidade



MLOps: engenharia que multiplica impacto

Resumo: MLOps transforma modelos de ML de experimentos isolados em sistemas confiáveis que geram valor contínuo. A investimento em pipelines, monitoramento e governança separa times que entregam de times que apenas experimentam.

Perspectiva Futura: LLMOps para grandes modelos de linguagem, plataformas de AI Governance e explainability automática serão exigidos tanto por reguladores quanto por usuários finais.



22%→90%

Modelos que chegam à produção com MLOps maduro

Times com MLOps Level 2+ entregam modelos 10x mais rápido com confiabilidade mensurável.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do experimento ao sistema que nunca para.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo