



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Deep Learning: **Aprendizado Profundo**

Redes neurais artificiais de múltiplas camadas que imitam o cérebro humano em tarefas complexas

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo



O que vamos explorar

Da rede neural às arquiteturas que definem o estado da arte da IA moderna

- | | | | |
|----|--|----|--|
| 01 | O que é Deep Learning e por que é diferente do ML clássico | 05 | RNNs e LSTMs: séries temporais e dados sequenciais |
| 02 | Redes Neurais Artificiais: neurônios, camadas e ativação | 06 | Transformers: a arquitetura que domina a IA moderna |
| 03 | Backpropagation e otimização: como a rede aprende | 07 | Transfer Learning e modelos de fundação geoespaciais |
| 04 | CNNs: visão computacional e imagens de satélite | 08 | Deep Learning aplicado a geotecnologias |

Redes neurais que aprendem representações do mundo

Deep Learning é um subconjunto de Machine Learning baseado em redes neurais artificiais com múltiplas camadas de transformação. Cada camada aprende representações progressivamente mais abstratas dos dados — do pixel ao objeto, da letra ao significado.

O que tornou DL o estado da arte foi a combinação de três fatores: grande volume de dados, GPUs paralelas de alta performance e avanços em arquiteturas como ResNet, LSTM e Transformer.

DEEP LEARNING EM 1 IDEIA

Camadas + Dados = Representação

- Aprende hierarquia automática de features
- Estado da arte em visão, linguagem e áudio
- Escala com mais dados e poder computacional

Seis arquiteturas fundamentais do Deep Learning

Cada arquitetura foi criada para capturar uma estrutura específica dos dados



Redes Densas (MLP/DNN)



CNNs — Visão Computacional



RNNs e LSTMs — Sequências



Transformers — Atenção



Autoencoders e U-Net



GANs — Modelos Generativos

CNNs: Visão Computacional e Imagens de Satélite

Redes Convolucionais (CNNs) aplicam filtros que detectam padrões locais — bordas, texturas, formas — de forma hierarquizada. Camadas iniciais detectam bordas; camadas profundas reconhecem objetos completos.

Em imagens de satélite, CNNs classificam uso do solo, detectam edifícios e estradas, segmentam corpos d'água e identificam focos de desmatamento com acurácia acima de 95% — superando classificação manual.

EXEMPLO PRÁTICO

U-Net para segmentação geoespacial: arquitetura CNN com skip connections amplamente usada para segmentação pixel a pixel de imagens de satélite — delimita lotes agrícolas, cursos d'água e áreas urbanas com precisão de 1 pixel.



U-NET

Segmentação pixel a pixel com CNN

U-Net + imagens Sentinel = demarcação automática de qualquer feição geoespacial com precisão centimétrica.

Transformers: a Revolução da Atenção

Transformers processam toda a sequência em paralelo via Self-Attention — cada elemento pondera a relevância de todos os outros. Mais eficientes que RNNs em sequências longas e paralelizáveis em GPU.

Dominam NLP (BERT, GPT), visão (ViT — Vision Transformer) e dados geoespaciais (Prithvi NASA/IBM, SatMAE). Vision Transformers aplicados a imagens de satélite superam CNNs em cenários de dados escassos com transfer learning.

EXEMPLO PRÁTICO

Prithvi (NASA + IBM): modelo de fundação geoespacial baseado em Transformer, pré-treinado em 6 anos de imagens HLS (Sentinel-2 + Landsat). Fine-tuning em minutos para classificação de cobertura, inundações e incêndios.



PRITHVI

Transformer geoespacial pré-treinado em satélite

*Fine-tuning de 1h substitui treino do zero de semanas —
Transformers democratizam DL geoespacial.*

Sequências, Transfer Learning e Modelos Generativos

LSTMs para séries temporais, transfer learning eficiente e GANs para dados sintéticos



RNNs e LSTMs

- LSTMs capturam dependências de longo prazo em séries — NDVI temporal, precipitação, sensores
- Previsão de estado vegetal futuro com base em série histórica de imagens de satélite
- GRU: versão mais leve do LSTM com performance similar para séries geoespaciais
- Aplicação: alertas de estresse hídrico na lavoura com semanas de antecedência



Transfer Learning e U-Net

- Pré-treino em ImageNet (1.2M imagens) e fine-tuning com poucas amostras geo
- U-Net: encoder-decoder com skip connections — padrão para segmentação geoespacial
- ResNet50 como backbone CNN + cabeça de classificação multi-classe para imagens Sentinel
- Reduz dados de treino necessários de 10.000 para 500 amostras rotuladas



GANs e Dados Sintéticos

- GANs geram imagens sintéticas de satélite para aumentar datasets de classes raras
- Super-resolução: SRGAN eleva resolução de imagens Landsat (30m) para nível Sentinel (10m)
- CycleGAN: converte imagens ópticas em SAR (radar) para análise em condições de nuvens
- Augmentação de dados: rotações, flips e jitter espectral multiplicam o dataset de treino

Pipeline de Deep Learning geoespacial

Do pixel ao produto cartográfico inteligente em cinco etapas



Deep Learning: inteligência que enxerga, ouve e prevê o território

Resumo: Deep Learning transformou o que é possível em análise geoespacial: CNNs que mapeiam o planeta pixel a pixel, LSTMs que preveem o futuro do território e Transformers que aprendem com bilhões de pixels de satélite. A barreira técnica cai rapidamente com modelos de fundação.

Perspectiva Futura: Modelos multimodais que combinam imagem de satélite + dados tabulares + coordenadas em um único Transformer geoespacial serão a próxima fronteira — unificando todas as fontes de dados geoespaciais num único sistema de aprendizado.



CNN + TRANSFORMER

DL que vê, aprende e mapeia o planeta

De U-Net para segmentação a Prithvi para classificação — DL no núcleo da DataGeo.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do pixel ao mapa inteligente.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo