



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Módulo 1: Formatos Eficientes para Big Geo Data

GeoParquet, Cloud Optimized GeoTIFF (COG), FlatGeobuf e STAC para dados geoespaciais em escala

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo

O que vamos explorar

Do shapefile lento ao GeoParquet rápido — formatos modernos para dados geo em escala

- | | | | |
|----|---|----|---|
| 01 | Por que Shapefile não escala: limitações do formato legado | 05 | STAC: catálogo padronizado de imagens de satélite |
| 02 | GeoParquet: dados vetoriais colunares e compressíveis | 06 | Leitura parcial: acessar apenas o que precisa |
| 03 | FlatGeobuf: streaming de dados vetoriais | 07 | Benchmark: GeoParquet vs Shapefile vs GeoJSON |
| 04 | Cloud Optimized GeoTIFF (COG): raster acessível por range request | 08 | Conclusão |

Shapefile tem 30 anos — existem alternativas muito melhores

Shapefile tem um limite de 2GB por arquivo, não suporta colunas de data/boolean e requer múltiplos arquivos (.shp, .dbf, .prj). GeoParquet resolve tudo isso: colunar, comprimido (Snappy/ZSTD), com suporte a todos os tipos e lido em paralelo por DuckDB, GeoPandas e Spark.

GEO EM 1 IDEIA

GeoParquet + DuckDB = Big Geo Data Local e Rápido

- GeoParquet: 10x mais comprimido que Shapefile
- COG: acessa trecho de GeoTIFF sem baixar o arquivo todo
- FlatGeobuf: streaming vetorial — lê por bounding box

Seis formatos modernos para Big Geo Data

De GeoParquet a STAC — formatos que escalam onde o Shapefile falha



GeoParquet — Colunar Geo



FlatGeobuf — Streaming



COG — Raster na Nuvem



STAC — Catálogo



Leitura Parcial e Lazy



Benchmark de Performance



GeoParquet: O Shapefile do Século XXI

GeoParquet armazena dados vetoriais no formato Apache Parquet — colunar, comprimido e particionável. `gpd.read_parquet('municipios.parquet')` lê 5x mais rápido que shapefile. DuckDB lê GeoParquet diretamente em SQL: `SELECT * FROM 'municipios.parquet' WHERE ST_Within(geometry, ST_GeomFromText('...'))`. Suporta arquivos de 10GB+ sem problemas.

EXEMPLO PRÁTICO

Exemplo prático: 150 milhões de endereços CNEFE: convertidos de CSV para GeoParquet com Snappy compressão reduziram de 45GB para 8GB — e DuckDB SQL geoespacial consultou os dados em 3 segundos vs 4 minutos no CSV original.




45GB → 8GB

GeoParquet reduziu 150M endereços em 82%

CSV 45GB → GeoParquet 8GB — DuckDB consulta em 3s vs 4min.

Do shapefile legado ao pipeline GeoParquet moderno

Quatro etapas da migração para formatos de Big Geo Data eficientes



Formatos modernos: Big Geo Data rápido e comprimido

Resumo: GeoParquet, COG e FlatGeobuf resolvem os limites do Shapefile para Big Geo Data: mais comprimidos, mais rápidos, particionáveis e acessíveis na nuvem sem download completo. A migração é simples e os ganhos são imediatos.

Perspectiva Futura: GeoParquet 1.0 aprovado como padrão OGC, suporte nativo em GeoPandas 1.0 e adoção em plataformas como Planetary Computer e AWS Open Data estão tornando o formato o novo padrão global de dados vetoriais.



GEOPARQUET + DUCKDB

Big Geo Data comprimido e rápido sem servidor

De shapefile a GeoParquet — 10x mais rápido, 5x menor, sem limite de 2GB.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do shapefile lento ao GeoParquet escalável.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo