



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Módulo 1: Autocorrelação e Clusters Espaciais

Índice de Moran I, LISA, hotspots, matrizes de peso espacial e PySAL com Python

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo

O que vamos explorar

Do Índice de Moran ao mapa de clusters LISA — estatística que vê padrões territoriais

- | | | | |
|----|--|----|--|
| 01 | Por que dados espaciais violam a independência estatística | 05 | Moran Scatterplot: visualizando autocorrelação |
| 02 | Matrizes de peso espacial: queen, rook e k-nearest | 06 | PySAL: biblioteca Python para estatística espacial |
| 03 | Índice de Moran I: autocorrelação global | 07 | Getis-Ord G_i^* : hot e coldspots significativos |
| 04 | LISA: Índices Locais de Associação Espacial | 08 | Conclusão |

Quando a localização altera a estatística

Dados geoespaciais violam um pressuposto fundamental da estatística clássica: a independência entre observações. Municípios vizinhos são mais similares entre si — autocorrelação espacial. Isso exige técnicas específicas: Índice de Moran, LISA e matrizes de peso que capturam a estrutura de vizinhança.

GEO EM 1 IDEIA

Moran I + LISA = Padrão Espacial Quantificado

- Moran I: de -1 (dispersão) a +1 (clustering)
- LISA localiza onde clusters se formam no mapa
- PySAL: biblioteca Python completa para estatística geo



Seis técnicas de estatística espacial exploratória

De Moran I a Getis-Ord — estatística que revela padrões que tabelas não mostram



Matrizes de Peso Espacial



Índice de Moran I



LISA — Clusters Locais



Moran Scatterplot



Getis-Ord G_i^*



PySAL em Python



Índice de Moran I: Quantificando Autocorrelação Espacial

`w = libpysal.weights.Queen.from_dataframe(gdf); mi = esda.Moran(gdf['idh'], w); print(mi.I, mi.p_sim)` — calcula Índice de Moran I e p-valor de permutação. I próximo de +1: municípios com alto IDH estão rodeados por outros de alto IDH (cluster). I próximo de -1: xadrez (outliers). I = 0: aleatoriedade.

EXEMPLO PRÁTICO

Exemplo prático: IDH municipal brasileiro (Censo 2022): Moran I = 0.74 ($p < 0.001$) — IDH extremamente clusterizado no espaço. LISA revelou cluster High-High (sul/sudeste) e Low-Low (semiárido nordestino/norte amazônico) — base para programas de intervenção territorial focalizados.



MORAN I = 0,74

IDH fortemente clusterizado no espaço brasileiro

PySAL + Queen weights + Moran I = autocorrelação espacial do IDH quantificada.

Do shapefile ao mapa de clusters LISA significativos

Quatro etapas da análise de autocorrelação espacial com PySAL

01



GeoDataFrame

Shapefile com atributo a testar carregado com GeoPandas.

02



Peso Espacial

Matriz Queen/Rook define quem são os vizinhos de cada unidade.

03



Moran I + LISA

PySAL calcula autocorrelação global e clusters locais significativos.

04



Mapa de Clusters

LISA High-High, Low-Low e outliers mapeados com categoria e p-valor.



Estatística espacial: rigor que revela o território

Resumo: Autocorrelação espacial não é detalhe técnico — é a propriedade fundamental que diferencia dados geoespaciais de dados tabulares comuns. Ignorá-la produz conclusões erradas; medi-la com Moran I e LISA revela padrões territoriais invisíveis a olho nu.

Perspectiva Futura: Integração de PySAL com GeoPandas e Libpysal está tornando a estatística espacial acessível a qualquer analista Python — sem necessidade de software estatístico especializado.



MORAN I + LISA

Autocorrelação espacial quantificada e mapeada

De Queen weights ao mapa LISA — estatística que revela o padrão territorial.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do Índice de Moran ao cluster que orienta política.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo