



DataGeo
Academy

CICLO DE FORMAÇÃO TÉCNICA

Módulo 2: Modelos Preditivos com Dados Geo

Feature engineering geoespacial, Random Forest espacial, GWR e validação de modelos territoriais

FLÁVIO ANTONIO OLIVEIRA DA SILVA

Engenheiro Cartógrafo



O que vamos explorar

Localização como variável preditiva — ML que entende o território

- | | | | |
|----|---|----|---|
| 01 | Dados geoespaciais como features preditivas | 05 | GWR: regressão geograficamente ponderada |
| 02 | Feature engineering geoespacial: distância, densidade e índices | 06 | Validação espacial: evitando data leakage geoespacial |
| 03 | Spatial lag: autocorrelação como feature preditiva | 07 | Mapas de resíduos e métricas de qualidade espacial |
| 04 | Random Forest e XGBoost com features geoespaciais | 08 | Conclusão |

Localização como a variável mais importante do modelo

Dados geoespaciais são variáveis explicativas de alto valor preditivo: latitude, longitude, distância a recursos, densidade de eventos por área, uso do solo e índices de vegetação capturam padrões que variáveis convencionais não conseguem.

Modelos preditivos com features geoespaciais superam modelos sem contexto espacial em praticamente todos os domínios: valor imobiliário, propagação de doenças, risco de crédito por área e rendimento agrícola.

FEATURE GEO EM 1 IMPACTO

R^2 +26% com features geoespaciais

- Distância, densidade e lag espacial como features
- Random Forest + features geo: $R^2 > 0.90$
- Validação espacial evita data leakage

Seis pilares da modelagem preditiva geoespacial

Do feature engineering à validação espacial — ML que respeita o espaço



Feature Engineering Geo



Spatial Lag Feature



Random Forest Espacial



GWR — Regressão Geo



Validação Espacial



Mapa de Resíduos



Feature Engineering Geoespacial

Features mais impactantes: lat/lon encodadas ciclicamente (sin/cos), distância ao recurso mais próximo (escola, hospital, metrô), densidade de eventos em raio definido (km²), índices espectrais de satélite (NDVI, EVI), spatial lag (valor médio dos vizinhos).

Spatial lag feature: inclui o valor médio dos k vizinhos mais próximos como feature — captura autocorrelação espacial que modelos convencionais ignoram. Implementação: `libpysal.weights.KNN + spatial_lag.lag_spatial()`.

EXEMPLO PRÁTICO

Valor imobiliário: adicionando distância ao metrô, NDVI do entorno, densidade de restaurantes em 500m e spatial lag do preço do bairro ao modelo: R^2 sobe de 0.72 para 0.91 — 26 pontos percentuais com features geoespaciais.



R^2 +26%

Ganho preditivo com feature engineering geo

Distância ao metrô + NDVI + spatial lag = 26pp de R^2 sem mudar o algoritmo.

Algoritmos e Validação Espacial

Random Forest, GWR e validação por bloco geográfico — ML que respeita o espaço



Random Forest Espacial

- RF e XGBoost robustos a features geoespaciais heterogêneas e não-lineares
- Feature importance: revela quais variáveis espaciais mais contribuem
- Treino por cluster espacial: evita data leakage — teste na área geográfica separada
- SHAP geoespacial: mapa de importância de features por região (Spatial SHAP)



GWR: Coeficientes que Variam no Espaço

- GWR: regressão que ajusta coeficientes diferentes por localização
- Mapa de coeficientes: onde cada variável tem mais impacto no modelo
- Captura heterogeneidade espacial — a relação entre variáveis muda por região
- Python: mgwr library — extensão multivariada e mais robusta do GWR clássico



Validação Espacial Correta

- Validação aleatória não serve para dados geo — vizinhos são similares (data leakage)
- Spatial block cross-validation: separa treino e teste por blocos geográficos
- BlockShuffleSplit (sklearn-evaluation): implementação Python de validação espacial
- Moran I dos resíduos: zero = modelo sem autocorrelação residual — validação aprovada

Pipeline de modelo preditivo geoespacial

Cinco etapas para construir modelos ML que entendem o território



Modelos que entendem onde o mundo acontece

Resumo: Feature engineering geoespacial e validação espacial correta são as práticas que separam modelos preditivos territorialmente precisos de modelos com aparência de boa performance mas inúteis para decisões regionais.

Perspectiva Futura: LLMs geoespaciais e modelos de fundação como Prithvi estão tornando o feature engineering geoespacial automatizado — reduzindo a barreira para modelagem preditiva territorial em qualquer setor.



FEATURE GEO + RF

Localização como variável preditiva estratégica

Do spatial lag ao mapa de SHAP values — ML que entende o território.



DataGeo
Academy

Obrigado!

Conhecimento que gera decisões — do modelo ao mapa preditivo.

FLÁVIO ANTONIO OLIVEIRA DA SILVA • Engenheiro Cartógrafo