



COLEÇÃO ACADÊMICA · DATAGEO ACADEMY

Machine Learning Geoespacial

IA e Machine Learning

12 capítulos · Laboratórios · Exercícios comentados

Autoria institucional: DataGeo Academy

Conhecimento que gera decisões | Edição 2.0 | 2026

Folha de rosto e controle documental

Machine Learning Geoespacial

IA e Machine Learning

Autoria institucional e edição: DataGeo Academy.

CAMPO	REGISTRO
Código	DGA-LPDF-01-02
Edição / ano	2.0 / 2026
Formato / extensão	PDF pesquisável / 42 páginas
Estrutura	12 capítulos; fundamentos, laboratório e exercícios
Natureza dos dados	Sintéticos, identificados em todos os laboratórios
Objetivo do volume	Aprendizagem supervisionada e não supervisionada aplicada a observações que possuem localização. A proximidade entre amostras exige planejamento de validação e atenção à dependência espacial.
Caso integrador	Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.
Rastreabilidade	Fontes e códigos incorporados ao PDF; referências no final

A autoria é institucional. Os laboratórios usam Python 3 e biblioteca padrão para cálculos de referência. Métodos especializados são contextualizados no conteúdo; exemplos numéricos não equivalem a validação de dados reais nem a resultado de cliente.

O controle documental identifica a edição e a finalidade. Ao adaptar os exercícios a um estudo profissional, registre fonte, versões, parâmetros e evidências. Preserve os dados de origem e documente a revisão técnica antes de usar resultados para decisão.

REVISÃO	ALTERAÇÃO
2.0	Expansão em PDF com 12 capítulos e exercícios comentados.
Uso em projeto	Registrar data, responsável, fontes e alterações realizadas.

Sumário técnico progressivo

CAP.	TEMA	PÁGINA
01	Problema, escopo e unidade de análise	5
02	Fontes, metadados e desenho amostral	8
03	Referência espacial, escalas e unidades	11
04	Preparação, ausências e consistência	14
05	Relacionamentos, vizinhança e atributos	17
06	Métodos, alternativas e baseline	20
07	Avaliação, métricas e resíduos	23
08	Sensibilidade, incerteza e limites	26
09	Agregação, indicadores e comunicação	29
10	Reprodutibilidade, automação e operação	32
11	Estudo aplicado e comparação de cenários	35
12	Exercícios integradores e revisão técnica	38

Cada capítulo ocupa três páginas: conceitos e critérios; laboratório reproduzível; exercícios e comentário de solução. A sequência avança da formulação do problema à revisão da entrega. Os marcadores laterais do PDF permitem navegar diretamente ao capítulo.

O código de cada laboratório e os dados sintéticos acompanham o PDF como arquivos incorporados. Para extraí-los, use um leitor que suporte anexos ou o script de extração fornecido no repositório. A fonte editorial identifica título, área, entradas e respostas de referência.

SEÇÃO COMPLEMENTAR	PÁGINA
Introdução e plano de estudo	4
Referências e aprofundamento	41
Projeto final e rubrica de avaliação	42

Introdução e plano de estudo

Aprendizagem supervisionada e não supervisionada aplicada a observações que possuem localização. A proximidade entre amostras exige planejamento de validação e atenção à dependência espacial.

O objetivo deste livro é apoiar o estudo de machine learning geoespacial com uma sequência verificável. O caso integrador é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. A leitura combina conceitos, procedimentos, cálculos e revisão, conectando a escolha de ferramentas ao problema e ao suporte dos dados.

Na área IA e Machine Learning, o trabalho exige atenção a alvo, atributos e generalização. O volume organiza essa atenção em doze capítulos, com exemplos pequenos que podem ser conferidos manualmente. O conjunto sintético permite distinguir falha aritmética, erro de preparação e hipótese de análise, sem apresentar números artificiais como observações de um território real.

O leitor deve conhecer tabelas, códigos, coordenadas e leitura de gráficos. Ao usar uma ferramenta especializada, consulte a documentação da versão efetivamente instalada. Os exemplos Python são independentes e servem à compreensão dos cálculos. Rotinas operacionais precisam de dados autorizados, controle de ambiente e testes próprios.

Recomenda-se ler os conceitos, executar o laboratório e responder às perguntas de diagnóstico nessa ordem. Compare a resposta numérica com a referência e redija uma justificativa temática. Uma divergência deve ser analisada, não apenas corrigida até coincidir com o número apresentado.

O exercício final reúne método, evidências e limitações. A finalidade é aprender a produzir resultados rastreáveis e a reconhecer condições em que faltam dados ou o método é inadequado. A quantidade de páginas não substitui revisão: decisões, unidades, cobertura e avaliação precisam permanecer coerentes do início ao fim.

COMPETÊNCIA	EVIDÊNCIA ESPERADA
1	Problema, alvo e unidade espacial
2	Construção de atributos geográficos
3	Treinamento e baseline
4	Validação espacial e interpretação
5	Aplicação e monitoramento

Plano sugerido: um capítulo por sessão de estudo, com execução e revisão do exercício. Reserve uma sessão adicional para comparar cenários e outra para organizar o relatório final. Registre dúvidas, fontes consultadas e decisões de adaptação.

CAPÍTULO 01 · FUNDAMENTOS E CRITÉRIOS

1. Problema, escopo e unidade de análise

1.1 Base conceitual

Uma análise começa com a definição do objeto, da unidade observada e da decisão que será apoiada. Localização não é um atributo decorativo: ela determina relações de vizinhança, cobertura e suporte. Uma estação mede condições locais; um setor reúne valores de uma área; um pixel registra uma resposta dentro de sua resolução. Resultados obtidos nesses suportes não são intercambiáveis sem uma regra de agregação.

Descreva o que está sendo contado, medido ou estimado, em qual período e com quais restrições. Uma pergunta operacional deve indicar destinatário, horizonte, produto e critério de sucesso. A lista de variáveis precisa separar dados disponíveis na decisão, informação derivada e resultado posterior. Usar um dado futuro em um modelo de antecipação torna a avaliação incompatível com o uso real.

O contrato de análise também precisa prever a ausência de informação. Sem uma regra explícita, sistemas podem apresentar zero quando não houve observação, misturando falha de coleta e ausência do fenômeno. Declare o significado de cada ausência e o comportamento esperado para amostras vazias, localidades fora da cobertura e períodos incompletos. Essas escolhas afetam o resultado antes de qualquer algoritmo.

1.2 Aplicação em Machine Learning Geoespacial

Aprendizagem supervisionada e não supervisionada aplicada a observações que possuem localização. A proximidade entre amostras exige planejamento de validação e atenção à dependência espacial.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Defina alvo e a data em que seus atributos estariam disponíveis.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	A pergunta é verificável e tem destinatário definido?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 01 · LABORATÓRIO REPRODUZÍVEL

1.3 Contrato e inventário

O laboratório representa seis observações sintéticas em coordenadas planas e um indicador genérico. Cada volume utiliza valores próprios para permitir conferir o cálculo. A população de referência é um denominador didático; não é população real de um município. O código separa identificador, grupo, coordenadas, observado e estimativa. No estudo do livro, adapte significado, fonte e unidade desses campos antes de interpretar resultados.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
     'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
     'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
     'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
     'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
     'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
     'denominador': 475},
]
# Contrato: coordenadas planas em metros; valores sintéticos.
ids = [p['id'] for p in DADOS]
assert len(ids) == len(set(ids))
for p in DADOS:
    assert p['grupo'] in ('A', 'B', 'C')
    for campo in ('e', 'n', 'observado', 'estimado'):
        assert math.isfinite(p[campo])
    assert p['denominador'] > 0
RESULTADO = {'registros': len(DADOS), 'ids_unicos': len(set(ids))}
print(RESULTADO)
```

Resultado de referência

```
{"ids_unicos": 6, "registros": 6}
```

A execução verifica unicidade e valores finitos. Essa verificação não prova representatividade, referência espacial correta ou validade temática. Inclua esses itens em controles separados, com evidências de origem. Para uma base real, um contrato também deve explicar licença, período, domínio, tolerância e conduta em caso de falta de um campo obrigatório.

Relação com o tema: Defina alvo e a data em que seus atributos estariam disponíveis. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 01 · EXERCÍCIOS E REVISÃO

1.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 01.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 01.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, defina alvo e a data em que seus atributos estariam disponíveis. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 01.C — Diagnóstico: responda “A unidade espacial e o período estão explicitados?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

1.5 Comentário de solução

O contrato encontra 6 registros e 6 identificadores únicos. A validação deve falhar se uma chave for repetida, um denominador for não positivo ou uma medida não for finita. Alterar o valor observado não muda a contagem, mas ainda precisa respeitar o contrato.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: A pergunta é verificável e tem destinatário definido? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

1.6 Critérios de aceite do exercício

- O produto atende à decisão ou apenas produz uma visualização?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 02 · FUNDAMENTOS E CRITÉRIOS

2. Fontes, metadados e desenho amostral

2.1 Base conceitual

O inventário deve registrar produtor, endereço de acesso, data de aquisição, versão, licença, tipo de observação, escala ou resolução e referência espacial. Dois arquivos com nomes semelhantes podem representar períodos ou critérios distintos. Preserve a origem e registre um identificador verificável, como hash, para distinguir versões. O hash confirma identidade binária, não precisão ou adequação temática.

A distribuição da amostra influencia o que se pode concluir. Pontos concentrados perto de vias podem super-representar áreas acessíveis. Registros administrativos refletem também procedimentos de notificação e atendimento. Um mapa de cobertura ajuda a distinguir concentração real do fenômeno de concentração de coleta. A ausência de registro em uma região pouco observada não demonstra ausência do evento.

Defina o papel de cada fonte no fluxo: referência, atributo explicativo, alvo ou validação independente. Uma mesma observação não deve ser reutilizada como prova independente do resultado que ajudou a produzir. Quando fontes possuem datas diferentes, explique a compatibilização ou restrinja a interpretação. Um inventário útil relaciona cada limitação ao efeito esperado no produto, em vez de listar metadados sem uso.

2.2 Aplicação em Machine Learning Geoespacial

Defina se a resposta representa classe, valor contínuo ou agrupamento. Uma célula de grade, lote ou município exige atributos e interpretação diferentes. Registre o período de validade do alvo e exclua variáveis que só seriam conhecidas depois do evento.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Separe referências de rótulo e fontes de atributos; mapeie sua cobertura.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	As fontes representam o mesmo período e população?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 02 · LABORATÓRIO REPRODUZÍVEL

2.3 Perfil de dados e cobertura

O resumo por grupo revela quantidade, distribuição e suporte. Os grupos representam áreas didáticas A, B e C, não recortes administrativos reais. Uma média por grupo pode ser igual mesmo quando cobertura, dispersão ou denominadores são diferentes. A tabela permite relacionar estatística e amostra antes de transformar valores ou escolher método.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
RESULTADO = {}
for grupo in ('A', 'B', 'C'):
    v = [p['observado'] for p in DADOS if p['grupo'] == grupo]
    RESULTADO[grupo] = {'n': len(v), 'min': min(v), 'max': max(v),
                        'media': statistics.mean(v)}
print(RESULTADO)
```

Resultado de referência

```
{ "A": { "max": 15.1, "media": 13.1, "min": 11.1, "n": 2 }, "B": { "max": 19.7, "media": 17.7,
"min": 15.7, "n": 2 }, "C": { "max": 24.3, "media": 22.3, "min": 20.3, "n": 2 } }
```

Não extrapole o perfil de seis registros a uma população. Em uso real, examine processo de seleção, tamanho dos grupos e cobertura em mapa. Estatística computada corretamente ainda pode descrever uma amostra enviesada. O produto deste laboratório é uma conferência do procedimento e uma lista de limitações para o tema do volume.

Relação com o tema: Separe referências de rótulo e fontes de atributos; mapeie sua cobertura. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 02 · EXERCÍCIOS E REVISÃO

2.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 02.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 02.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, separe referências de rótulo e fontes de atributos; mapeie sua cobertura. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 02.C — Diagnóstico: responda “Há regiões sem suporte amostral?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

2.5 Comentário de solução

As médias por grupo são A: 13.1000, B: 17.7000, C: 22.3000. Cada grupo contém duas observações. Alterar o primeiro observado afeta o resumo do grupo A, sem alterar B e C. O tamanho da amostra e sua cobertura ainda precisam ser avaliados no caso real.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: As fontes representam o mesmo período e população? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

2.6 Critérios de aceite do exercício

- Qual dado pode servir de avaliação independente?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 03 · FUNDAMENTOS E CRITÉRIOS

3. Referência espacial, escalas e unidades

3.1 Base conceitual

Um sistema de referência identifica como as coordenadas se relacionam à Terra. Definir o CRS de valores existentes e transformar valores entre CRSs são operações diferentes. Atribuir EPSG:31982 a coordenadas em graus não as converte em metros. Antes da transformação, confira referência de origem, ordem dos eixos, datum, zona, hemisfério e extensão plausível.

Cálculos planos de distância e área exigem unidades e projeção adequadas. Latitude e longitude não são metros. Para dados geodésicos, use métodos que tratem a superfície e as unidades explicitamente. SIRGAS 2000 / UTM 22S atende a uma faixa longitudinal específica; não é uma projeção única para todo o Brasil. Altura elipsoidal e altitude vinculada a referência vertical também não são sinônimos.

Escala e resolução delimitam o detalhe interpretável. Reamostrar uma imagem para pixels menores não cria informação nova. Agregar observações pode reduzir ruído, mas também esconder variações locais. Declare a unidade de cada indicador e converta somente quando a grandeza permitir. Transformação correta de coordenadas não corrige automaticamente erro de medição ou de identificação da fonte.

3.2 Aplicação em Machine Learning Geoespacial

Harmonize CRS, período e escala. Calcule distâncias em unidade adequada; agregue indicadores sem duplicar observações em joins. Separe ausência real, valor zero e informação indisponível.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Confirme suporte do pixel ou unidade territorial antes de associar atributos.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	As coordenadas são graus ou metros?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 03 · LABORATÓRIO REPRODUZÍVEL

3.3 Distância e escala

As coordenadas do laboratório são planas, em metros, com referência local didática. A expressão raiz de delta E ao quadrado mais delta N ao quadrado calcula distância horizontal no plano. Não aplica correção de projeção, distância de terreno ou deslocamento por rede. O azimuth começa no norte e cresce no sentido horário; pontos coincidentes não definem direção.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
a, b = DADOS[0], DADOS[-1]
de, dn = b['e'] - a['e'], b['n'] - a['n']
distancia = math.hypot(de, dn)
if distancia == 0:
    raise ValueError('Pontos coincidentes: azimuth indefinido.')
azimute = math.degrees(math.atan2(de, dn)) % 360
RESULTADO = {'distancia_m': distancia, 'azimute_graus': azimute}
print(RESULTADO)
```

Resultado de referência

```
{"azimute_graus": 73.30075576600639, "distancia_m": 417.612260356422}
```

Compare esses valores apenas dentro do sistema indicado. Em longitude e latitude, o mesmo código não produz metros. Para dados reais, escolha cálculo geodésico ou projeção adequada e documente transformação. Em análise de acesso, distância euclidiana é um baseline; tempo de viagem exige rede, modo e condições operacionais.

Relação com o tema: Confirme suporte do pixel ou unidade territorial antes de associar atributos. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 03 · EXERCÍCIOS E REVISÃO

3.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 03.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 03.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, confirme suporte do pixel ou unidade territorial antes de associar atributos. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 03.C — Diagnóstico: responda “A projeção é adequada à região e ao cálculo?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

3.5 Comentário de solução

Distância entre primeiro e último ponto = 417.6123 m; azimute = 73.3008 graus. O cálculo usa coordenadas planas locais. Mudar o observado não altera distância ou direção; mudar coordenadas altera ambos. Não aplique essa fórmula a graus para obter metros.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: As coordenadas são graus ou metros? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

3.6 Critérios de aceite do exercício

- O detalhe da saída é sustentado pela fonte?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

4. Preparação, ausências e consistência

4.1 Base conceitual

Preparação combina validação de tipos, domínios, chaves, datas e geometrias. Diferencie valor ausente, zero, texto inválido e resultado não aplicável. Converter uma coluna com falhas para número deve produzir um registro de rejeições. Não remova linhas silenciosamente: a distribuição dos registros descartados pode indicar viés regional ou temporal.

Uma imputação precisa de hipótese. Mediana reduz sensibilidade a extremos, mas não resolve ausência não aleatória nem preserva variação local. Quando o objetivo envolve previsão, parâmetros de imputação devem ser aprendidos somente no treino e aplicados aos demais conjuntos. Tratar o conjunto inteiro antes de separar treino e teste pode transferir informação de avaliação para o modelo.

A validação geométrica individual não equivale à topologia entre feições. Um polígono válido pode se sobrepor indevidamente a outro; uma linha válida pode estar desconectada da rede esperada. Regras dependem do tema e da finalidade. Guarde geometria original, regra aplicada, alteração efetuada e motivo de aceitação antes de substituir um dado em uma base compartilhada.

4.2 Aplicação em Machine Learning Geoespacial

Compare um modelo simples com árvores ou ensembles. Ajuste transformações somente no treino e preserve identificadores para auditoria. Use Pipeline para aplicar o mesmo procedimento aos conjuntos de avaliação.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Aprenda imputação somente no treino; documente rótulos ausentes.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	O tratamento de ausência tem hipótese documentada?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 04 · LABORATÓRIO REPRODUZÍVEL

4.3 Tratamento de ausência

O exemplo introduz uma ausência em um atributo numérico e calcula a mediana a partir dos demais valores. A regra é determinística e pode ser conferida manualmente. A linha com ausência permanece identificada, permitindo distinguir dado original e valor tratado. Não há alegação de que a mediana seja sempre a melhor hipótese para o tema.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
v = [p['observado'] for p in DADOS]
v[2] = None # Ausência didática, preservando o registro.
mediana = statistics.median(x for x in v if x is not None)
tratado = [mediana if x is None else x for x in v]
RESULTADO = {'mediana': mediana, 'original': v, 'tratado': tratado}
print(RESULTADO)
```

Resultado de referência

```
{"mediana": 19.7, "original": [11.1, 15.1, null, 19.7, 20.3, 24.3], "tratado": [11.1, 15.1,
19.7, 19.7, 20.3, 24.3]}
```

A ausência pode depender de localização, período ou processo de coleta. Substituí-la por um único número pode reduzir variabilidade e alterar relações. Em modelagem, calcule o parâmetro somente no treino. Em indicadores oficiais, avalie se imputação é permitida ou se a saída deve ser marcada como indisponível. Registre a decisão e seu impacto.

Relação com o tema: Aprenda imputação somente no treino; documente rótulos ausentes. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 04 · EXERCÍCIOS E REVISÃO

4.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 04.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 04.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, aprenda imputação somente no treino; documente rótulos ausentes. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 04.C — Diagnóstico: responda “As rejeições alteram a cobertura de dados?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

4.5 Comentário de solução

A mediana dos valores disponíveis é 19.7000. O terceiro registro recebe esse valor e deve permanecer marcado como tratado. Mudar uma observação pode alterar a mediana e o valor imputado. Em uso preditivo, estime esse parâmetro somente com dados de treino.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: O tratamento de ausência tem hipótese documentada? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

4.6 Critérios de aceite do exercício

- A regra de consistência corresponde ao significado do tema?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 05 · FUNDAMENTOS E CRITÉRIOS

5. Relacionamentos, vizinhança e atributos

5.1 Base conceitual

Joins relacionam registros por chaves ou predicados espaciais. Antes de unir tabelas, declare a cardinalidade esperada: um para um, um para muitos ou muitos para muitos. Uma junção espacial pode gerar múltiplas correspondências legítimas. Se cada registro expandido for somado como novo evento, os totais serão inflados. Confira contagens e chaves antes e depois de cada operação.

Vizinhança representa uma hipótese sobre relação territorial. Contiguidade, raio de distância, k vizinhos e conexão por rede produzem conjuntos diferentes. Um buffer circular representa proximidade geométrica, não tempo de deslocamento. Informe como áreas isoladas, pontos na borda e múltiplas correspondências serão tratados. O predicado contém pode distinguir borda de interior de maneira diferente de cobre.

Atributos derivados precisam preservar significado e momento de disponibilidade. Distância a uma infraestrutura, densidade de eventos e resumo por território devem ter unidades, suporte e fonte. Normalização pode facilitar comparação, mas não elimina diferenças de qualidade ou escala. Identificadores quase únicos não devem substituir atributos explicativos: podem permitir memorização sem generalização.

5.2 Aplicação em Machine Learning Geoespacial

Separe regiões ou blocos no treino e teste. Informe métricas por bloco, matriz de confusão e desempenho por classe. Importância de atributos não demonstra causalidade e pode ser instável com variáveis correlacionadas.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Teste joins sem multiplicar rótulos e exclua identificadores que memorizem a resposta.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	A cardinalidade foi conferida por chave?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 05 · LABORATÓRIO REPRODUZÍVEL

5.3 Relação e vizinhança

O código enumera vizinhos dentro de um raio fixo em coordenadas planas. A relação inclui a borda por usar comparação menor ou igual. Cada identificador aparece uma vez na origem, mas pode ter vários vizinhos; somar registros da lista de relações como novos eventos seria incorreto. O raio tem unidade em metros e uma finalidade de demonstração.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
raio = 150.0 # metros, sistema plano local didático
RESULTADO = {}
for a in DADOS:
    RESULTADO[a['id']] = [b['id'] for b in DADOS if b['id'] != a['id']
    and math.hypot(b['e']-a['e'], b['n']-a['n']) <= raio]
print(RESULTADO)
```

Resultado de referência

```
{"P01": ["P02"], "P02": ["P01", "P03"], "P03": ["P02", "P04"], "P04": ["P03", "P05"], "P05":
["P04", "P06"], "P06": ["P05"]}
```

Uma vizinhança por distância difere de contiguidade ou conexão por rede. Compare a regra com a pergunta do caso. Para tabelas grandes, use índice ou estrutura adequada; o laço completo é uma referência simples de complexidade quadrática. Não confunda teste de igualdade geométrica com deduplicação de objetos distintos no mesmo endereço.

Relação com o tema: Teste joins sem multiplicar rótulos e exclua identificadores que memorizem a resposta. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 05 · EXERCÍCIOS E REVISÃO

5.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 05.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 05.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, teste joins sem multiplicar rótulos e exclua identificadores que memorizem a resposta. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 05.C — Diagnóstico: responda “A vizinhança representa o processo estudado?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

5.5 Comentário de solução

A quantidade de vizinhos por ponto é P01: 1, P02: 2, P03: 2, P04: 2, P05: 2, P06: 1. Alterar observado não muda vizinhança; raio ou coordenada pode mudar. A lista descreve relações, não novos eventos. Confira o tratamento de pontos coincidentes e de distância exatamente igual ao raio.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: A cardinalidade foi conferida por chave? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

5.6 Critérios de aceite do exercício

- Os atributos estarão disponíveis no momento de aplicação?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 06 · FUNDAMENTOS E CRITÉRIOS

6. Métodos, alternativas e baseline

6.1 Base conceitual

Um baseline é uma alternativa simples usada como referência. Ele pode ser uma média histórica, persistência temporal, regra explícita ou consulta direta, conforme o problema. Comparar apenas métodos complexos entre si não demonstra benefício sobre uma solução simples. Defina o baseline antes de escolher parâmetros e mantenha condições de avaliação equivalentes.

A escolha do método deve considerar hipóteses, unidade de entrada, custo de manutenção e forma de falha. Um resultado visualmente suave pode esconder ausência de suporte; uma classificação de alta acurácia pode ignorar a classe rara. Uma consulta rápida pode responder a uma definição incorreta. Registre o que o método calcula e o que ele não permite concluir, vinculando essas limitações à decisão.

Comparações precisam controlar dados, partições e critérios. Não atribua a um algoritmo uma melhora produzida por mudança de amostra ou por acesso a informação adicional. Se houver ajuste de parâmetros, use um conjunto apropriado de validação e preserve teste final. Inclua o esforço operacional: resultado que exige dados indisponíveis ou manutenção inviável pode não atender ao uso pretendido.

6.2 Aplicação em Machine Learning Geoespacial

Gere o mapa de predição com máscara para locais sem suporte de dados. Registre versão do modelo, CRS, fontes e domínio de aplicação. Compare novos períodos com o treinamento para detectar mudança de distribuição.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Compare regra simples, árvore e método do tema em condição equivalente.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	O baseline atende à mesma pergunta?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 06 · LABORATÓRIO REPRODUZÍVEL

6.3 Baseline e comparação

Duas alternativas são avaliadas sobre os mesmos valores: média do conjunto e estimativa sintética fornecida na tabela. O resultado da estimativa foi construído apenas para estudar métricas; ele não vem de um modelo treinado nem de um levantamento. Portanto, a comparação é uma demonstração de cálculo, não evidência de superioridade de algoritmo.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
obs = [p['observado'] for p in DADOS]
pred = [p['estimado'] for p in DADOS]
media = statistics.mean(obs) # Apenas baseline descritivo do exemplo.
mae_media = statistics.mean(abs(media-x) for x in obs)
mae_estimativa = statistics.mean(abs(a-b) for a,b in zip(obs,pred))
RESULTADO = {'media': media, 'mae_media': mae_media,
              'mae_estimativa_sintetica': mae_estimativa}
print(RESULTADO)
```

Resultado de referência

```
{"mae_estimativa_sintetica": 1.3200000000000003, "mae_media": 3.733333333333334, "media": 17.7}
```

Em avaliação real, a média de baseline deve ser aprendida no treino e aplicada ao teste. Usar a média de todo o teste como método comparativo pode fornecer informação indisponível na operação. Registre partição, horizonte, referência e hipótese do baseline. A alternativa simples precisa atender à mesma pergunta do método principal.

Relação com o tema: Compare regra simples, árvore e método do tema em condição equivalente. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 06 · EXERCÍCIOS E REVISÃO

6.4 Caderno de aplicação

ALTERNATIVA	CONTRIBUIÇÃO	LIMITAÇÃO
Regra ou média de referência	Interpretação simples e baixo custo	Pode ignorar relações importantes
Árvores e ensembles	Relações não lineares e interação	Precisam de avaliação independente
Redes neurais	Representação aprendida de dados complexos	Exigem dados e controle de treinamento

1. Exercício 06.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 06.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, compare regra simples, árvore e método do tema em condição equivalente. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 06.C — Diagnóstico: responda “A comparação usa a mesma amostra e o mesmo horizonte?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

6.5 Comentário de solução

Média de referência = 17.7000; MAE dessa média = 3.7333; MAE da estimativa sintética = 1.3200. A comparação usa o mesmo conjunto e serve ao cálculo. Não comprova superioridade de modelo treinado nem generalização a dados reais.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: O baseline atende à mesma pergunta? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

6.6 Critérios de aceite do exercício

- As hipóteses do método são plausíveis neste território?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 07 · FUNDAMENTOS E CRITÉRIOS

7. Avaliação, métricas e resíduos

7.1 Base conceitual

Avaliação mede a distância entre o resultado e uma referência independente. Em variável contínua, MAE é a média do erro absoluto e RMSE é a raiz da média do erro quadrático. Ambos mantêm a unidade da variável, mas RMSE dá mais peso a erros grandes. Viés médio preserva sinal e pode revelar superestimação ou subestimação; erros positivos e negativos podem se cancelar.

Em classificação, a matriz de confusão organiza classes reais e previstas. Precisão avalia acerto entre positivos previstos; revocação avalia detecção entre positivos reais. Acurácia isolada pode ser alta quando uma classe domina a amostra. Declare qual classe é positiva, limiar, custo dos erros e tratamento de denominadores nulos. Não converta uma pontuação em probabilidade sem avaliar calibração.

Métricas agregadas precisam ser acompanhadas de distribuição e localização dos erros. Analise resultados por grupo, período e faixa do indicador. Dependência entre amostras reduz a independência da avaliação; divisões por região ou tempo podem ser mais coerentes com o uso real. Teste o modelo na condição de generalização pretendida, não apenas na condição mais conveniente para obter uma métrica favorável.

7.2 Aplicação em Machine Learning Geoespacial

Reserve regiões ou cenas e analise matriz de confusão ou resíduos.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Reserve regiões ou cenas e analise matriz de confusão ou resíduos.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	A referência é independente do procedimento?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 07 · LABORATÓRIO REPRODUZÍVEL

7.3 Métricas e resíduos

O código calcula erro como estimado menos observado, MAE, RMSE e viés. Os denominadores são o número de observações válidas. O erro absoluto mantém magnitude; o quadrático dá maior peso a discrepâncias grandes; o viés mantém sinal. A tabela por registro ajuda a localizar erros que se cancelam na média.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
e = [p['estimado']-p['observado'] for p in DADOS]
RESULTADO = {'mae': statistics.mean(abs(x) for x in e),
    'rmse': math.sqrt(statistics.mean(x*x for x in e)),
    'vies': statistics.mean(e)}
print(RESULTADO)
```

Resultado de referência

```
{"mae": 1.3200000000000003, "rmse": 1.4314095617024971, "vies": 0.25666666666666654}
```

Essas métricas são adequadas a valores contínuos comparáveis na mesma unidade. Para classes ou probabilidades, adapte avaliação ao alvo: matriz de confusão, métricas de detecção ou calibração. Não selecione a métrica depois de ver qual produz a melhor narrativa. Defina o critério em função da decisão e examine desempenho por grupo.

Relação com o tema: Reserve regiões ou cenas e analise matriz de confusão ou resíduos. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 07 · EXERCÍCIOS E REVISÃO

7.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 07.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 07.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, reserve regiões ou cenas e analise matriz de confusão ou resíduos. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 07.C — Diagnóstico: responda “A métrica corresponde à decisão e à unidade?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

7.5 Comentário de solução

MAE = 1.3200; RMSE = 1.4314; viés = 0.2567. Confira erro por registro e explique diferença entre magnitude e sinal. Esses números não são limites universais de aprovação; uma mudança em observado afeta erro e métricas.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: A referência é independente do procedimento? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

7.6 Critérios de aceite do exercício

- Onde estão os erros que a média global esconde?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 08 · FUNDAMENTOS E CRITÉRIOS

8. Sensibilidade, incerteza e limites

8.1 Base conceitual

Uma análise de sensibilidade examina como a saída responde a mudanças controladas de entradas, pesos ou parâmetros. Ela identifica escolhas às quais o resultado é vulnerável. Não equivale automaticamente a um intervalo probabilístico: perturbações arbitrárias não representam distribuição de erro conhecida. Registre a justificativa de cada cenário e mantenha separado o que é hipótese do que foi observado.

Incerteza pode vir de medição, cobertura, resolução, modelo e decisão. Intervalos gerados por um método normalmente representam apenas parte dessas fontes. Um intervalo estreito não garante qualidade quando o modelo omite uma fonte dominante de erro. Descreva limites do domínio de aplicação e confira se novas entradas permanecem próximas às condições avaliadas.

Apresente cenários comparáveis e a consequência prática de diferenças nos resultados. Para rankings, verifique se pequenas mudanças alteram posições. Para limiares, examine valores próximos ao corte. Para mapas, identifique áreas de baixo suporte. A revisão deve informar quando o produto suporta a decisão, quando exige observações adicionais e quando não deve ser usado naquela finalidade.

8.2 Aplicação em Machine Learning Geoespacial

Examine estabilidade de previsão e explicação sob mudança plausível de entrada.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Examine estabilidade de previsão e explicação sob mudança plausível de entrada.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	A perturbação corresponde a uma fonte de incerteza plausível?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 08 · LABORATÓRIO REPRODUZÍVEL

8.3 Perturbação e sensibilidade

O laboratório altera a estimativa por menos dez por cento, valor original e mais dez por cento. Os cenários tornam explícito que uma escolha de entrada ou parâmetro pode modificar erro e viés. As três perturbações são hipóteses didáticas, não quantis de uma distribuição de incerteza conhecida.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
RESULTADO = {}
for fator in (0.9, 1.0, 1.1):
    e = [p['estimado']*fator-p['observado'] for p in DADOS]
    RESULTADO[fator] = {'mae': statistics.mean(abs(x) for x in e),
                        'vies': statistics.mean(e)}
print(RESULTADO)
```

Resultado de referência

```
{"0.9": {"mae": 1.7086666666666679, "vies": -1.539}, "1.0": {"mae": 1.3200000000000003,
"vies": 0.25666666666666654}, "1.1": {"mae": 2.1663333333333337, "vies": 2.0523333333333342}}
```

Não chame a amplitude dos cenários de intervalo de confiança. Para inferência probabilística, é necessário um modelo de erro e um procedimento adequado. Observe se o resultado atravessa limiares da decisão e se a mudança é consistente entre grupos. Explicar o mecanismo da alteração é mais útil que apresentar apenas uma faixa numérica.

Relação com o tema: Examine estabilidade de previsão e explicação sob mudança plausível de entrada. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 08 · EXERCÍCIOS E REVISÃO

8.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 08.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 08.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, examine estabilidade de previsão e explicação sob mudança plausível de entrada. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 08.C — Diagnóstico: responda “O resultado muda perto de um limiar importante?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

8.5 Comentário de solução

O MAE por fator de perturbação é 0.9: 1.7087, 1.0: 1.3200, 1.1: 2.1663. A alteração demonstra sensibilidade aritmética e pode mudar a conclusão. A amplitude entre cenários não é intervalo de confiança: não há distribuição probabilística de erro definida.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: A perturbação corresponde a uma fonte de incerteza plausível? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

8.6 Critérios de aceite do exercício

- Quais erros não estão representados no intervalo apresentado?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

9. Agregação, indicadores e comunicação

9.1 Base conceitual

Agregação precisa respeitar a natureza da medida. Contagens podem ser somadas quando os eventos são exclusivos; taxas devem preservar numerador e denominador; estoque depende do instante observado. A média simples de taxas de unidades com populações diferentes pode produzir uma interpretação distinta da taxa global ponderada. Documente o grão e os componentes antes de resumir.

Mapas, tabelas e gráficos comunicam aspectos complementares. Um mapa coroplético exige cuidado com área territorial e denominadores. Classes de legenda e escala podem destacar ou esconder diferenças; não altere discretização para favorecer uma conclusão. Mostre unidade, período e fonte e ofereça uma tabela para conferência dos valores que o mapa representa.

Uma entrega clara separa descrição, interpretação e recomendação. Informe o que foi calculado, em quais condições e com quais limitações. O leitor deve conseguir identificar filtros ativos, dados ausentes e diferenças entre observado e estimado. Acessibilidade requer contraste, símbolos e texto; não dependa apenas de cores para comunicar estados críticos ou classes de informação.

9.2 Aplicação em Machine Learning Geoespacial

Apresente erros por classe e região, junto ao mapa de suporte amostral.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Apresente erros por classe e região, junto ao mapa de suporte amostral.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	A agregação preserva numeradores e denominadores?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 09 · LABORATÓRIO REPRODUZÍVEL

9.3 Agregação e taxa

O exercício compara média simples das taxas e taxa do total. A primeira dá o mesmo peso a cada registro; a segunda soma numeradores e denominadores compatíveis. Os denominadores foram construídos para evidenciar a diferença. Uma taxa deve informar sua base, como por cem unidades, e o período a que os componentes se referem.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
taxas = [100*p['observado']/p['denominador'] for p in DADOS]
total_n = sum(p['observado'] for p in DADOS)
total_d = sum(p['denominador'] for p in DADOS)
RESULTADO = {'media_taxas': statistics.mean(taxas),
              'taxa_total': 100*total_n/total_d}
print(RESULTADO)
```

Resultado de referência

```
{"media_taxas": 7.043483227299017, "taxa_total": 6.156521739130435}
```

O indicador genérico do laboratório não é automaticamente uma contagem de eventos; a taxa aqui é uma operação aritmética de estudo. Em base real, confirme que o numerador e a população em risco permitem essa razão. Não some estoques de instantes diferentes nem taxas já normalizadas como se fossem contagens exclusivas.

Relação com o tema: Apresente erros por classe e região, junto ao mapa de suporte amostral. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 09 · EXERCÍCIOS E REVISÃO

9.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 09.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 09.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, apresente erros por classe e região, junto ao mapa de suporte amostral. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 09.C — Diagnóstico: responda “A legenda está coerente com unidade e período?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

9.5 Comentário de solução

Média simples das taxas = 7.0435; taxa dos totais = 6.1565, ambas na base por cem unidades. A diferença vem dos pesos dos denominadores. Antes de interpretar, confira se a variável pode ser numerador de uma taxa e se população e período são compatíveis.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: A agregação preserva numeradores e denominadores? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

9.6 Critérios de aceite do exercício

- O destinatário consegue conferir valores e filtros?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 10 · FUNDAMENTOS E CRITÉRIOS

10. Reprodutibilidade, automação e operação

10.1 Base conceitual

Reprodutibilidade depende de fontes identificadas, parâmetros declarados e ambiente conhecido. Separe dados de origem, intermediários e produtos finais. Registre versão de software, comando de execução, configuração e resultado de validação. Um pipeline deve explicitar o que escreve e evitar sobrescrever a única cópia da fonte.

Idempotência significa que repetir a mesma operação, sob as mesmas condições, não deve acumular duplicatas ou alterar resultados indevidamente. Use chaves, transações e gravações controladas. Uma falha intermediária precisa deixar um estado identificável e recuperável. Logs devem relacionar etapa, entrada, saída e erro, sem registrar credenciais ou dados pessoais desnecessários.

Operação inclui permissões, monitoramento, atualização e recuperação. Crie perfis de acesso adequados à tarefa, verifique fontes indisponíveis e detecte mudanças de schema. Backup só demonstra recuperação quando uma restauração foi testada. Declare responsável, rotina de revisão e condições de reprocessamento para que o produto não dependa exclusivamente de conhecimento informal de uma pessoa.

10.2 Aplicação em Machine Learning Geoespacial

Registre versão do modelo, transformação dos atributos e domínio de aplicação.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Registre versão do modelo, transformação dos atributos e domínio de aplicação.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	Uma execução nova reproduz o produto?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 10 · LABORATÓRIO REPRODUZÍVEL

10.3 Manifesto e reprodução

Um manifesto registra nome do volume, parâmetros e hash dos dados serializados em ordem definida. Isso permite identificar o conjunto utilizado e repetir cálculos. JSON com chaves ordenadas evita diferenças apenas de ordem dos campos; o hash muda se qualquer valor ou representação relevante mudar.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
texto = json.dumps(DADOS, sort_keys=True, ensure_ascii=False)
RESULTADO = {'registros': len(DADOS),
    'sha256_dados': hashlib.sha256(texto.encode('utf-8')).hexdigest(),
    'referencia': 'plano local didatico, metros',
    'natureza': 'dados sinteticos'}
print(RESULTADO)
```

Resultado de referência

```
{"natureza": "dados sinteticos", "referencia": "plano local didatico, metros", "registros": 6,
"sha256_dados": "19e6de08565f03dd7afbce5362555b8d6512dede4d9283e5ff52141a02f4e32f"}
```

O manifesto não substitui fonte autorizada, contrato de schema ou registro de ambiente. Uma execução reproduzível inclui versão de dependências e conduta em erros. Não grave segredos nem dados pessoais desnecessários nos logs. Para cargas em banco ou serviços, acrescente transação, política de repetição e estado de recuperação.

Relação com o tema: Registre versão do modelo, transformação dos atributos e domínio de aplicação. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 10 · EXERCÍCIOS E REVISÃO

10.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 10.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 10.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, registre versão do modelo, transformação dos atributos e domínio de aplicação. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 10.C — Diagnóstico: responda “A repetição cria duplicatas ou sobrescreve fontes?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

10.5 Comentário de solução

O manifesto identifica 6 registros e produz SHA-256 que começa por 19e6de08565f03dd. Mudar uma observação muda o hash. Isso detecta mudança binária da representação serializada, mas não demonstra qualidade temática, autorização de uso ou validade científica.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: Uma execução nova reproduz o produto? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

10.6 Critérios de aceite do exercício

- Há procedimento testável para falha e recuperação?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 11 · FUNDAMENTOS E CRITÉRIOS

11. Estudo aplicado e comparação de cenários

11.1 Base conceitual

O estudo aplicado integra as etapas sem trocar silenciosamente sua pergunta inicial. Defina um conjunto pequeno com resultado verificável antes de usar uma base grande. Os exemplos sintéticos ajudam a conferir cálculo, chaves e unidades, mas não substituem validação temática com observações reais. Registre de forma visível o caráter demonstrativo dos dados.

Organize cenários alterando uma hipótese por vez quando a finalidade for interpretar efeitos. Preserve os demais componentes para atribuir diferenças à mudança examinada. Quando variáveis mudarem simultaneamente, trate o resultado como cenário conjunto. Não confunda associação observada, desempenho preditivo e efeito causal de uma intervenção.

A conclusão precisa relacionar resultado, critério e limitação. Se o critério não foi atendido, identifique se a causa foi dado insuficiente, método inadequado, implementação ou incompatibilidade com a decisão. Uma execução sem erro de software não comprova validade científica. Apresente evidências que permitam revisão e reconheça situações que exigem coleta adicional ou outro desenho de análise.

11.2 Aplicação em Machine Learning Geoespacial

Compare uma região conhecida e uma região reservada sem refazer o teste para favorecer o modelo.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Compare uma região conhecida e uma região reservada sem refazer o teste para favorecer o modelo.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	O caso mantém a pergunta e a unidade definidas?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 11 · LABORATÓRIO REPRODUZÍVEL

11.3 Cenário com grupo reservado

O código reserva o grupo C e calcula um baseline com os grupos A e B. O desenho imita a ideia de aplicar um procedimento a um grupo não usado para ajustar o parâmetro. O conjunto pequeno permite calcular manualmente a média de treino e o erro do grupo reservado, sem confundir aprendizado e avaliação.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
treino = [p['observado'] for p in DADOS if p['grupo'] != 'C']
teste = [p['observado'] for p in DADOS if p['grupo'] == 'C']
media_treino = statistics.mean(treino)
RESULTADO = {'media_treino': media_treino,
    'n_treino': len(treino), 'n_teste': len(teste),
    'mae_teste': statistics.mean(abs(x-media_treino) for x in teste)}
print(RESULTADO)
```

Resultado de referência

```
{ "mae_teste": 6.9000000000000002, "media_treino": 15.399999999999999, "n_teste": 2, "n_treino": 4 }
```

Esse exemplo não estabelece independência espacial real nem poder estatístico: os grupos e valores são sintéticos. Em um estudo, escolha bloco ou período pela escala do processo e mantenha teste final fora das escolhas de modelo. Se o teste for consultado repetidamente para escolher parâmetros, ele deixa de ser uma avaliação final independente.

Relação com o tema: Compare uma região conhecida e uma região reservada sem refazer o teste para favorecer o modelo. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 11 · EXERCÍCIOS E REVISÃO

11.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 11.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 11.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, compare uma região conhecida e uma região reservada sem refazer o teste para favorecer o modelo. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 11.C — Diagnóstico: responda “As diferenças entre cenários têm hipótese identificada?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

11.5 Comentário de solução

O treino contém 4 registros e o grupo reservado contém 2. Média de treino = 15.4000; MAE no grupo C = 6.9000. Mudar um observado do treino pode mudar o baseline; mudar apenas o teste deve alterar avaliação, não o parâmetro aprendido.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: O caso mantém a pergunta e a unidade definidas? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

11.6 Critérios de aceite do exercício

- A conclusão é proporcional à evidência produzida?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

CAPÍTULO 12 · FUNDAMENTOS E CRITÉRIOS

12. Exercícios integradores e revisão técnica

12.1 Base conceitual

O exercício integrador deve produzir evidências de todas as decisões importantes: fonte, unidade, preparação, método, avaliação e entrega. Cada exercício precisa ter entrada, procedimento, saída esperada e critério de aceitação. Resultado numérico conhecido facilita identificar erro de implementação; pergunta aberta permite discutir hipóteses e limites que um teste automatizado não avalia.

Faça primeiro uma verificação de casos simples, depois examine casos extremos. Inclua amostra vazia, ausência, denominador zero, chave duplicada, coordenada inadequada e mudança de período. Nem toda entrada inválida deve ser corrigida automaticamente. Em vários casos, o comportamento correto é interromper e informar a condição, preservando a fonte para revisão.

A revisão deve separar erro de cálculo, escolha de método e interpretação. Se os testes numéricos passarem, ainda será necessário conferir significado dos dados e adequação à decisão. Prepare um relatório curto com procedimento reproduzível, resultados, ressalvas relevantes e próximos passos. A documentação torna as limitações verificáveis e permite melhorar o trabalho em uma execução posterior.

12.2 Aplicação em Machine Learning Geoespacial

Revise erros raros, casos fora do domínio e documentação da decisão.

ELEMENTO	DECISÃO TÉCNICA
Objeto do estudo	amostra rotulada
Procedimento em foco	Revise erros raros, casos fora do domínio e documentação da decisão.
Risco a controlar	vazamento de informação e dependência entre amostras
Evidência requerida	Há critérios de aceitação para os cálculos?

O caso integrador deste volume é: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos. Aplique os critérios acima ao suporte e à finalidade desse caso, separando resultado calculado de interpretação temática.

CAPÍTULO 12 · LABORATÓRIO REPRODUZÍVEL

12.3 Testes e revisão

Os testes verificam cálculo, entrada vazia e coerência da identidade dos registros. Casos conhecidos são úteis para detectar regressões em rotinas. Valores iguais produzem erro zero; uma previsão deslocada por duas unidades tem MAE de duas unidades. O código rejeita listas incompatíveis, evitando uma comparação silenciosa de observações erradas.

Python 3 · Biblioteca padrão

```
import math, statistics, json, hashlib
DADOS = [
    {'id': 'P01', 'grupo': 'A', 'e': 100, 'n': 200, 'observado': 11.1, 'estimado': 9.78,
    'denominador': 100},
    {'id': 'P02', 'grupo': 'A', 'e': 180, 'n': 260, 'observado': 15.1, 'estimado': 15.87,
    'denominador': 175},
    {'id': 'P03', 'grupo': 'B', 'e': 260, 'n': 320, 'observado': 15.7, 'estimado': 18.01,
    'denominador': 250},
    {'id': 'P04', 'grupo': 'B', 'e': 340, 'n': 200, 'observado': 19.7, 'estimado': 19.04,
    'denominador': 325},
    {'id': 'P05', 'grupo': 'C', 'e': 420, 'n': 260, 'observado': 20.3, 'estimado': 21.95,
    'denominador': 400},
    {'id': 'P06', 'grupo': 'C', 'e': 500, 'n': 320, 'observado': 24.3, 'estimado': 23.09,
    'denominador': 475},
]
def mae(obs, pred):
    if not obs or len(obs) != len(pred):
        raise ValueError('Vetores vazios ou incompatíveis.')
    return statistics.mean(abs(a-b) for a,b in zip(obs,pred))
assert mae([1,2,3], [1,2,3]) == 0
assert mae([1,2,3], [3,4,5]) == 2
try:
    mae([], [])
except ValueError:
    RESULTADO = {'testes': 3, 'situacao': 'aprovados'}
else:
    raise AssertionError('Entrada vazia aceita indevidamente.')
print(RESULTADO)
```

Resultado de referência

```
{"situacao": "aprovados", "testes": 3}
```

Testes numéricos não avaliam sozinhos precisão da fonte, hipótese científica ou interpretação. Separe revisão automática e revisão temática. Acrescente entradas específicas do assunto do livro e documente resultados observados. O exercício final exige um relatório que conecte método, evidência, limitações e ação proposta.

Relação com o tema: Revise erros raros, casos fora do domínio e documentação da decisão. O exemplo é aritmético e sintético; dados e método específicos de machine learning geoespacial devem respeitar as hipóteses discutidas neste capítulo.

CAPÍTULO 12 · EXERCÍCIOS E REVISÃO

12.4 Caderno de aplicação

ID / GRUPO	OBSERVADO	ESTIMADO	DENOM.
P01 / A	11.10	9.78	100
P02 / A	15.10	15.87	175
P03 / B	15.70	18.01	250
P04 / B	19.70	19.04	325
P05 / C	20.30	21.95	400
P06 / C	24.30	23.09	475

1. Exercício 12.A — Cálculo: reproduza o laboratório deste capítulo com os dados abaixo, registre a saída e confira um resultado manualmente. Preserve unidades e explique o significado da operação. Depois substitua o primeiro valor observado por observado + 2 e identifique quais saídas devem mudar.
2. Exercício 12.B — Aplicação: no caso “Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.”, revise erros raros, casos fora do domínio e documentação da decisão. Registre fonte necessária, parâmetro, evidência de verificação e uma condição em que a etapa deve ser interrompida.
3. Exercício 12.C — Diagnóstico: responda “As entradas inválidas são tratadas explicitamente?”. Construa um exemplo de erro relacionado a vazamento de informação e dependência entre amostras e mostre como ele pode produzir saída numericamente plausível, mas incompatível com a decisão.

12.5 Comentário de solução

Os três testes passam: previsão igual à observação tem MAE zero; deslocamento uniforme de duas unidades tem MAE dois; vetor vazio é rejeitado. Acrescente caso incompatível, não finito e uma entrada específica do tema. Testes aritméticos não dispensam revisão da hipótese e da fonte.

Conecte alvo, atributos e generalização ao objeto e período do caso. Critério: Há critérios de aceitação para os cálculos? A resposta deve identificar fonte, parâmetro e evidência. Diferencie medida, cálculo e hipótese; uma saída plausível não demonstra adequação temática.

Uma execução sem exceção não elimina vazamento de informação e dependência entre amostras. Rastreie a etapa problemática, preserve a entrada original e compare parâmetros. Justifique a correção sem inventar observações ou eliminar registros apenas para melhorar uma métrica.

12.6 Critérios de aceite do exercício

- O relatório distingue resultado, hipótese e recomendação?
- Entrada, procedimento e saída conferidos; divergências justificadas.
- Limites de aplicação e próxima verificação registrados.

Referências e aprofundamento

As referências abaixo são documentação oficial para consulta dos conceitos operacionais e das ferramentas relacionadas à área. A organização didática e os exemplos sintéticos foram preparados para esta edição. A leitura técnica deve ser complementada com bibliografia especializada, desenho amostral e revisão do uso pretendido.

- https://scikit-learn.org/stable/modules/cross_validation.html
- <https://docs.python.org/3/library/statistics.html>
- <https://docs.python.org/3/library/math.html>

Como verificar uma referência

- Confirme versão do software e seção correspondente ao procedimento utilizado.
- Relacione a afirmação à documentação que realmente a sustenta.
- Registre parâmetros, unidades, opções e comportamento em dados ausentes.
- Teste o exemplo em conjunto conhecido antes de aplicar a uma base extensa.
- Separe método documentado de hipótese específica do estudo.

As páginas de documentação podem evoluir. Registre a data de consulta e mantenha compatibilidade com seu ambiente. Não atribua à referência uma aprovação da aplicação, da amostra ou do resultado deste livro. A documentação explica funções e métodos; a adequação ao problema requer critérios e evidências.

Para aprofundar machine learning geoespacial, transforme o caso integrador em um plano de pesquisa ou projeto. Identifique dados adicionais, critérios de seleção, comparação de alternativas e validação independente. Aplique as perguntas dos capítulos como roteiro de revisão e registre o efeito de escolhas relevantes.

Os anexos incorporados incluem os doze laboratórios e o conjunto de dados. A execução pode ser refeita em ambiente Python 3 sem acesso à rede. Eles são uma referência didática de cálculo; não instalam serviços, não publicam dados nem substituem ferramentas especializadas do tema.

ANEXO INCORPORADO	CONTEÚDO
dados_sinteticos.json	Seis observações, grupos, coordenadas e valores.
capitulo_01.py a capitulo_12.py	Códigos independentes e executáveis.
fonte_editorial.json	Tema, área, contexto, caso e capítulos.

Projeto final e rubrica de avaliação

Projeto: Classificar áreas com maior propensão a expansão urbana a partir de cobertura do solo, distâncias a vias e indicadores demográficos.

O trabalho deverá demonstrar alvo, atributos e generalização em um fluxo reproduzível. Escolha fonte autorizada ou mantenha o conjunto sintético identificado. Entregue inventário, critérios, procedimento e relatório. Não substitua falta de dado por resultado inventado.

DIMENSÃO	CRITÉRIO	PONTOS
Escopo	Pergunta, unidade, período e objetivo explícitos.	15
Dados	Origem, referência, domínio e cobertura documentados.	20
Método	Etapas e parâmetros justificados.	20
Avaliação	Baseline, erros e casos inválidos conferidos.	20
Comunicação	Resultado, limitações e reprodução claros.	15
Revisão	Erros tratados e evidências preservadas.	10

Sequência de entrega

1. Descreva a decisão e prepare uma versão pequena da base com resultado verificável.
2. Registre fontes e aplique regras de preparação com relatório de rejeições.
3. Execute o método e compare com baseline pertinente à tarefa.
4. Avalie cenários, resíduos e limitações de suporte ou horizonte.
5. Produza mapa ou tabela com unidades e origem; organize o procedimento.
6. Peça a um revisor para reproduzir a execução e justificar divergências.

Comentário orientador

A melhor entrega não é a de maior complexidade, mas a que responde à pergunta com dados e hipóteses rastreáveis. Erros numéricos precisam de correção; falta de cobertura precisa de reconhecimento e eventualmente coleta; hipótese inadequada exige revisão do desenho. Explicita qual dessas situações foi encontrada.

No tema Machine Learning Geoespacial, examine especialmente vazamento de informação e dependência entre amostras. Demonstre uma conferência concreta que detecte esse problema. Uma conclusão válida deve identificar domínio de aplicação, evidência disponível e próxima ação, sem transformar previsão ou estimativa em certeza.

A rubrica orienta estudo e revisão. A pontuação não constitui habilitação profissional ou certificação. Após concluir, registre uma revisão do trabalho, preservando o histórico das alterações e as razões que levaram a mudar dados, parâmetros ou interpretação.